




Sistemi Informativi

Prof. Matteo Golfarelli

Alma Mater Studiorum - Università di Bologna

Integrazioni di basi di dati




I motivi

I sistemi informativi aziendali (come quelli per la contabilità, la gestione del magazzino, il CRM, ecc.) non nascono tutti insieme. Vengono sviluppati o acquisiti in momenti diversi, aggiungendo "pezzi" man mano che l'azienda cresce o cambiano le esigenze.

- Lo sviluppo di un sistema informativo è di tipo **incrementale** ed **evolutivo** e quindi il suo risultato è un mosaico composto da più frammenti ognuno dei quali utilizza la tecnologia in voga al momento della sua realizzazione e che modella la realtà esistente in quel momento

La cosa più critica è che ogni frammento modella la realtà in modo leggermente diverso. Ad esempio, un vecchio sistema di fatturazione potrebbe chiamare un cliente "Codice Cliente", mentre il nuovo sistema di marketing lo chiama "ID Azienda". Entrambi si riferiscono alla stessa entità, ma con definizioni, strutture e regole diverse. Questo crea il bisogno di integrazione.



- Per operare efficacemente con le informazioni è necessario che:
 - Il modello della realtà utilizzato sia consistente e veritiero (problema del *divario percettivo*).
 - I dati siano consistenti e corretti.
- Il raggiungimento di questo ambizioso risultato necessita di un processo di **integrazione**, **pulizia** e **trasformazione** dei dati che può richiedere un elevato dispendio di tempo e di risorse.

Integrare le varie sorgenti di dati nel sistema complessivo

(richiede periodicamente o continuamente dei nuovi cicli di integrazione, pulizia e trasformazione) 3

Riguarda la struttura e la definizione dei dati. È la descrizione di come i dati sono organizzati, incluse le tabelle, gli attributi, i tipi di dato, le chiavi e i vincoli. È il "modello" o la "regola".

Riguarda le istanze o i valori effettivi contenuti nelle tabelle. Sono le occorrenze concrete dei dati che cambiano nel tempo. È la "realizzazione" o il "contenuto".

Aspetti intensionali ed estensionali


- ❑ Con il termine di **integrazione** si indicano l'insieme di attività atte a costruire una versione integrata e consistente del sistema informatico.
 - **Integrazione dello schema:** operazione a livello intensionale che rende consistenti gli schemi dei diversi moduli.
 - **Trasformazione dei dati:** operazione a livello estensionale che trasforma i dati degli schemi locali nei dati dello schema globale.
 - **Pulizia dei dati:** operazione a livello estensionale che controlla ed elimina eventuali inconsistenze ed errori.

Input: vari Schemi sorgenti operazionali.

Processo: L'obiettivo è risolvere i conflitti tra i diversi schemi. Questo può includere l'identificazione di omonimie (stesso nome, significato diverso) e sinonimie (nomi diversi, stesso significato).

Output:
- Schema Riconciliato: Il modello unificato e consistente che rappresenta la visione aziendale unica.
- Mapping Sorgenti Operazionali: Le regole che specificano come gli elementi dello schema sorgente corrispondono agli elementi dello schema riconciliato.

Archiviazione: Sia lo Schema Riconciliato che i Mapping sono memorizzati nei Metadati (dati sui dati), essenziali per le fasi successive.



Input: Campioni dei dati (dati reali prelevati dalle sorgenti).

Processo: Qui si definiscono le regole per correggere i dati:

- Rimozione di Duplicati: Unificare record che si riferiscono alla stessa entità.
- Correzione di Errori.
- Gestione di Valori Mancanti: Imputare o standardizzare i campi vuoti.

Output: Regole di pulizia specifiche.

Processo: Questa fase utilizza il Mapping creato nell'integrazione dello schema per convertire i valori affinché si adattino al modello globale.

ETL (Extract, Transform, Load) descrive il processo fondamentale e la tecnologia chiave utilizzata per l'integrazione, la pulizia e la trasformazione dei dati da diverse sorgenti in un unico sistema di destinazione, tipicamente un Data Warehouse (DW).

I passi dell'integrazione dello schema

Risultato: Un insieme di schemi concettuali che sono localmente completi e consistenti (ovvero, ben definiti e senza ambiguità interne a quel singolo schema), pronti per essere confrontati e unificati.

❑ Analizzando più in dettaglio la fase di integrazione si evidenziano le seguenti operazioni:

1 Analisi e normalizzazione: consiste nell'analizzare i diversi schemi locali producendo come risultato un insieme di schemi concettuali localmente completi e consistenti.

Si studiano i modelli concettuali e logici di ogni base di dati sorgente per capirne la struttura, le definizioni e i vincoli. Si trasformano gli schemi locali in un formato concettuale comune. Questa operazione è cruciale per rendere omogenea la rappresentazione prima di tentare la fusione.

2 Definizione dello schema riconciliato: è la fase più importante in cui i diversi schemi locali vengono fusi in un unico schema globalmente consistente.

3 Definizione del mapping: utilizzando lo schema logico riconciliato si definisce la relazione (mapping) tra concetti degli schemi sorgenti e dello schema riconciliato.

Schemi Locali ¹ --> Schemi Ristrutturati ² --> Schema Globale ³ --> Regole ETL/Traduzione

- Si definiscono le regole di corrispondenza (il mapping) tra ogni elemento (tabelle, attributi, relazioni) dello Schema Locale (sorgente) e l'elemento corrispondente dello Schema Riconciliato (target). Queste regole possono essere semplici o complesse.
- Ruolo Cruciale: Il mapping è fondamentale perché:
 - > Guida la Trasformazione (ETL): Le regole di mapping sono la base per scrivere le procedure di trasformazione dei dati.
 - > Supporta il Query Rewriting: Nei sistemi di integrazione virtuale, il mapping viene usato per tradurre le query sul modello globale nelle query appropriate da eseguire sulle basi di dati sorgente.
- Risultato: Un insieme di regole formali che collegano i concetti sorgente al concetto globale, che vengono poi archiviate nei metadati.


Identificazione e Risoluzione dei Conflitti: Si risolvono i problemi di divergenza semantica:

- Sinonimi: Due nomi diversi che rappresentano lo stesso concetto. Si sceglie un unico nome canonico.
- Omonimi: Lo stesso nome che rappresenta concetti diversi. Si deve rinominare almeno uno.
- Conflitti Strutturali: La stessa informazione è rappresentata in modi diversi. Si sceglie una rappresentazione unica.
- Integrazione/Fusione: Gli schemi ristrutturati vengono fusi per formare lo Schema Riconciliato, che è la visione globalmente consistente e completa.

Risultato: Lo Schema Globale, il modello di riferimento unico che definisce l'organizzazione dei dati per tutto il sistema integrato (es. Data Warehouse).

I passi dell'integrazione

(parte intensionale, cioè integrazione a livello di schema)



Architettura per il SI integrato

Vantaggi: I dati sono sempre aggiornati in tempo reale. Non è necessario spazio aggiuntivo per memorizzare una copia duplicata dei dati.
Svantaggi: Le query possono essere lente, poiché il sistema deve eseguire il query rewriting, comunicare con diversi database eterogenei e unificare i risultati in tempo reale.


❑ La presenza di un livello di dati integrato modifica l'architettura del SI



Livello delle applicazioni:

- interfaccia
- logica applicativa

→ Le applicazioni, anziché interrogare direttamente i database sorgente (spesso eterogenei), interrogano una vista unica che aderisce allo Schema Riconciliato (globale).



Schema globale (Schema riconciliato)

Schemi locali

Viene definita solo la meta-conoscenza necessaria. Questo significa che solo lo Schema Globale e i Mapping con le sorgenti sono memorizzati (i Metadati).

- I dati integrati vengono creati solo quando richiesti da una query.
- > L'applicazione interroga lo Schema Globale.
- > Il sistema di integrazione usa i Mapping per tradurre la query globale in una o più query specifiche per gli schemi locali (Query Rewriting).
- > Le query vengono eseguite sulle sorgenti, i risultati vengono raccolti, unificati al volo e restituiti all'applicazione.

❑ Le applicazioni operano su viste dello schema integrato che può essere:

Virtuale: viene definita solo la meta-conoscenza necessaria a ottenere le informazioni sullo schema globale. Queste saranno create solo quando richieste mediante interrogazioni eseguite sugli schemi locali. Questa soluzione è quella maggiormente utilizzata (es. SI distribuiti, SI confederati, SI eterogenei).

Non esiste una copia fisica dei dati integrati

In questa architettura, l'integrazione è fisica. I dati vengono estratti, trasformati, puliti e memorizzati permanentemente in una nuova base di dati centrale.

Materializzato: i dati vengono trasformati e memorizzati in versione duplicata. Questa soluzione viene utilizzata per esempio nei sistemi DW. (Datawarehouse)

Il processo ETL è lo strumento che esegue questa materializzazione

I dati vengono trasformati e memorizzati in una versione duplicata (la "Materializzazione"). Lo Schema Globale è popolato con i dati unificati. L'applicazione interroga direttamente il Data Warehouse.

Vantaggi e Svantaggi sono gli opposti

→ Si aggiunge la possibilità di applicare ETL

Architettura per il SI integrato

- ❑ A causa della complessità dell'operazione non è sempre possibile ottenere un unico schema globale; talvolta può essere sufficiente creare poche porzioni integrate a partire da molti schemi locali.

sottoinsieme di progetto integrazione, in cui integrazione non al 100% di tutti i dati, ma solo su quelli importanti per l'azienda (viene fatto per limitare i costi o rendere possibile una cosa che non sarebbe possibile)

- ❑ **Master Data Management (MDM):** l'integrazione è limitata ai dati aziendali critici

Il Master Data Management è una strategia e una disciplina specifica che incarna questa integrazione focalizzata: l'integrazione è limitata ai dati aziendali critici.

- Cos'è il Master Data? I Master Data sono dati che non cambiano ad ogni singola operazione e che sono essenziali per il funzionamento dell'azienda.

- Lo Scopo dell'MDM: L'obiettivo è creare una "Single Version of the Truth" per ogni entità Master Data. Se un cliente è registrato con variazioni in tre sistemi diversi (CRM, ERP e Logistica), il sistema MDM esegue le operazioni di pulizia, unificazione e riconciliazione per creare e mantenere un'unica versione autorevole, coerente e corretta di quel cliente.

- Il Contesto dell'MDM nell'Architettura: L'MDM agisce come una fonte di dati di riferimento centrale che alimenta sia i sistemi operativi (per garantire che i nuovi dati inseriti siano conformi) sia i sistemi di Business Intelligence/Data Warehouse (per garantire che le analisi siano basate su anagrafiche coerenti).

- Vantaggio: Concentrando gli sforzi di integrazione e pulizia sui dati più importanti, l'azienda ottiene il massimo beneficio in termini di coerenza dei processi e affidabilità del reporting, senza dover integrare ogni singolo frammento di dato minore.

L'idea di ottenere un unico, gigantesco e perfetto Schema Globale che copra ogni singolo dato di tutti i sistemi locali è spesso un obiettivo irraggiungibile o economicamente insostenibile. La realtà operativa porta ad approcci più limitati e focalizzati:

- Integrazione Parziale/Focalizzata: Invece di tentare di fondere tutti gli schemi locali, si scelgono solo le porzioni critiche necessarie per una specifica esigenza.
- > Si creano poche porzioni integrate (o Data Marts, se in un contesto Materializzato) che coprono segmenti specifici, attingendo dai molti schemi locali.

Progetto di integrazione: abbiamo 2..n sorgenti dati e vogliamo fare un'integrazione complessiva di tutti i dati. Creare un nuovo DB o layer dati virtuale o materializzato che sia l'unione di tutti i dati. (non sempre possibile: costi economici, complessità).

L'obiettivo principale di questa fase, applicata a ogni schema sorgente separatamente, è duplice: comprendere completamente lo schema locale e portarlo a un formato concettuale standard (normalizzazione/ristrutturazione).

Spesso queste dipendenze sono implicite nella logica applicativa o nelle prassi aziendali.

Analisi e normalizzazione

→ Cerco di capire Quali sono i concetti del dominio e Qual'è lo schema teorico che rappresenta questi dati

☐ Durante la fase di analisi il progettista, confrontandosi con gli esperti del dominio applicativo, deve verificare la completezza degli schemi locali, sforzandosi di individuare eventuali correlazioni involontariamente omesse:

Il progettista deve trovare i legami e le regole di business che esistono nella realtà, ma non sono esplicitamente dichiarati nel database

- Esplicitazione di dipendenze funzionali precedentemente tralasciate
- Individuazione di nuove associazioni tra le entità.

Trovare relazioni non esplicite tra tabelle.

☐ Non si possono aggiungere entità o attributi che non hanno un corrispettivo ricavabile dai dati esistenti.

Per poter confrontare e fondere gli schemi (il passo successivo, l'Integrazione degli Schemi), tutti i modelli devono essere espressi usando lo stesso formalismo

☐ Le trasformazioni apportate allo schema non devono però introdurre nuovi concetti (assenti nei dati presenti sulle sorgenti), bensì esplicitare tutti quelli ricavabili dai dati memorizzati nelle sorgenti operazionali.

→ Si deve solo esplicitare (formalizzare) la conoscenza che è già implicita nei dati, nella struttura logica o nelle regole del dominio. L'obiettivo è trasformare uno schema imperfetto o incompleto in uno schema concettuale completo della realtà che modella.


☐ Lo schema concettuale viene ottenuto tramite Reverse Engineering dallo schema implementato (dalle tabelle che si trovano nel DB locale)

☐ Lo schema concettuale delle sorgenti rappresenta senz'altro il risultato principale dell'analisi, e deve essere espresso mediante lo stesso formalismo per tutte le sorgenti. Dove assente esso deve essere ricavato per **reverse engineering**.

sforzo abbastanza complesso da effettuare

Non sempre abbiamo accesso allo schema implementato: d esempio, in un ERP, essendo parametrizzato, abbiamo accesso ad una meta-modellazione⁹ (concetti molto generali, di difficile interpretazione dal progettista)

Analisi e normalizzazione



Il problema dell'integrazione é sempre quello di riconoscere e risolvere le diversità/non-uguaglianze a livello di schema/istanza che ho sui concetti comuni

I problemi da affrontare

Prossimo passo: ho degli schemi normalizzati, li ho capiti, so il loro contenuto e ora li devo mettere insieme

- ❑ Se le diverse sorgenti dati modellassero porzioni indipendenti e distinte del mondo reale, il problema dell'integrazione non sussisterebbe.
- ❑ Ciò non può avvenire in pratica poiché ogni azienda è un universo ^{di processi} coeso in cui le diverse unità organizzative partecipano a processi comuni che condividono tutti o parte degli attori. (vari processi si basano sugli stessi concetti)

Le diversità nelle rappresentazioni dei concetti comuni sono causate da:

- 3 livelli di incongruenza
- A ➤ **Diversità di prospettiva.** Lo stesso concetto del mondo reale è modellato in modo diverso a seconda di chi lo usa. Le proprietà (attributi) associate allo stesso concetto possono variare.
 - B ➤ **Equivalenza dei costrutti del modello.** Si verificano quando la stessa informazione è rappresentata utilizzando costrutti diversi all'interno dello stesso modello di dati
 - C ➤ **Incompatibilità delle specifiche.** Questi conflitti riguardano la rappresentazione concreta a livello di tipo di dato o unità di misura

Scopriremo che mettendo insieme più informazioni che prima erano separate, emergeranno delle nuove informazioni

- ❑ La fase di integrazione non si deve limitare a evidenziare le differenze di rappresentazione dei concetti comuni a più schemi, ma deve anche identificare l'insieme di concetti distinti e memorizzati in schemi differenti che sono correlati attraverso proprietà semantiche (**proprietà inter-schema**). L'integrazione non è solo unificare ciò che è uguale ma diverso, ma anche collegare ciò che è diverso ma correlato. Proprietà Inter-Schema: Sono relazioni logiche che esistono tra concetti che non sono gli stessi e non sono modellati nello stesso schema, ma hanno un legame semantico cruciale.
cioè potremo fare delle interrogazioni sql o lanciare codice e rispondere a domande a cui non potevamo rispondere se le sorgenti erano separate


Diversità di prospettiva

La diversità di prospettiva si verifica perché diversi gruppi di utenti (reparti aziendali) utilizzano e modellano lo stesso oggetto del mondo reale, ma si concentrano solo sugli aspetti rilevanti per la loro specifica funzione.


- Il punto di vista rispetto al quale diversi gruppi di utenti vedono uno stesso oggetto del dominio applicativo, può differenziarsi notevolmente in base agli aspetti rilevanti ai fini della funzione a cui essi sono preposti.

➤ Quello di destra è una porzione dello schema utilizzato per gestire l'organigramma aziendale per il quale non è rilevante la distribuzione dei dipendenti sui vari progetti.

Determinare se la relazione tra i due schemi è dovuta a un'effettiva diversità semantica/prospettiva, oppure se lo schema di destra è semplicemente derivabile (ristrutturabile) da quello di sinistra.



In questo caso, lo schema di destra non può essere calcolato o dedotto in modo semplice da quello di sinistra, e viceversa. Entrambe le prospettive devono essere mantenute e fuse nello schema globale per creare una visione completa. Questo richiede la risoluzione dei conflitti e la fusione degli schemi.




Il problema non è che uno schema sia sbagliato, ma che entrambi sono parzialmente corretti per il loro scopo specifico.

Per creare lo Schema Riconciliato (Globale), il sistema di integrazione deve: Capire che l'entità DIPENDENTE a sinistra è semanticamente la stessa entità DIPENDENTE a destra. Creare un'unica entità DIPENDENTE nel modello globale. Includere entrambe le relazioni nello schema globale. L'entità DIPENDENTE globale dovrà avere sia la relazione "partecipa a PROGETTO" sia la relazione "è assegnato a DIPARTIMENTO".


In sostanza, l'integrazione deve superare la visione parziale di ogni reparto per creare una visione olistica e completa, dove tutte le prospettive legittime sono conservate e unificate.

Equivalenza dei costrutti del modello

- I formalismi di modellazione permettono di rappresentare uno stesso concetto utilizzando combinazioni diverse dei costrutti a disposizione.
 - La diversità è puramente di tipo sintattico: le due modellazioni sono perfettamente equivalenti.



Tutte le istanze che stanno in un DB posso essere caricate sull'altro e viceversa





Ciò significa che, pur appearing diversi, entrambi gli schemi contengono esattamente la stessa informazione e modellano le stesse regole di business. L'informazione può essere ricavata dall'una o dall'altra rappresentazione.

Differenze: nello schema di sinistra, per essere inserita una istanza di Casa Editrice bisogna avere almeno un libro di essa, mentre di là rientra nella stessa entità. Problema di ridondanza: essendo lo schema di sinistra normalizzato e l'altro no, in quello di destra bisogna manualmente aggiornare i campi dopo che un valore di, ad esempio, casa editrice è stato cambiato

Equivalenza dei costrutti del modello

- I formalismi di modellazione permettono di rappresentare uno stesso concetto utilizzando combinazioni diverse dei costrutti a disposizione.
 - La diversità è puramente di tipo sintattico: le due modellazioni sono perfettamente equivalenti.





Questa diversità non è dovuta a come sono disegnati gli schemi (conflitto sintattico) o a cosa significano i concetti (conflitto semantico), ma a come sono specificati i vincoli e i formati: Conflitto semantico: Riguarda il significato di un concetto (La differenza è nel dominio applicativo.). Conflitto Sintattico: Riguarda la forma in cui lo stesso concetto è modellato (La differenza è nella struttura del modello.).

Incompatibilità delle specifiche

- Si verifica quando due schemi modellano una stessa porzione del dominio applicativo e racchiudono concetti diversi, in contrasto tra loro. Tale diversità deriva normalmente da errate scelte progettuali che possono coinvolgere per esempio la scelta dei nomi, dei tipi di dati e dei vincoli di integrità.

I due schemi sono incompatibili poiché quello in quello di sinistra un professore può tenere al più un corso mentre in quello di destra deve tenerne almeno due.

Bisogna capire cosa è successo (tramite dati, interviste e formalismi)



Questi conflitti si manifestano a vari livelli:

Conflitti di Nomi (Omonimie/Sinonimie): Sebbene non siano i più difficili, la scelta di nomi diversi per lo stesso concetto (sinonimia) o lo stesso nome per concetti diversi (omonimia) richiede una risoluzione.

Conflitti di Tipo di Dato/Formato: Ad esempio, se un campo Prezzo è definito come intero in un sistema e decimale in un altro.

Conflitti di Vincoli di Integrità (Il Caso Più Critico): Il caso mostrato nel diagramma rientra in questa categoria. Le regole di business (cardinalità) sono in conflitto.

Concetti comuni

presenti negli schemi

- *) Nessun conflitto.
- B) Conflitto strutturale/sintattico.
- A) Conflitto semantico/di prospettiva.
- C) Conflitto di specifiche/vincoli.

- È necessario definire il tipo di relazione ~~semantica~~ esistente tra concetti comuni modellati diversamente in schemi distinti. Quattro sono le possibili relazioni esistenti tra due distinte rappresentazioni R_1 e R_2 di uno stesso concetto:

- ⊗ ➤ **Identità:** vengono utilizzati gli stessi costrutti, il concetto è modellato dallo stesso punto di vista e non vengono commessi errori di specifica; in altre parole quando R_1 e R_2 coincidono. Utilizzano gli stessi costrutti, modellano il concetto dallo stesso punto di vista (stessa semantica) e non hanno errori di specifica (stessi vincoli, stessi tipi di dato, stessi nomi).
- ⓑ ➤ **Equivalenza:** R_1 e R_2 non sono esattamente le stesse poiché sono stati utilizzati costrutti diversi (ma equivalenti) e non sussistono errori di specifica o diversità di percezione. Le rappresentazioni non sono identiche, ma sono perfettamente equivalenti a livello informativo. La diversità è puramente sintattica o strutturale. Non ci sono conflitti di semantica o di vincoli.
- Ⓐ ➤ **Comparabilità:** R_1 e R_2 non sono né identici né equivalenti, ma i costrutti utilizzati e i punti di vista dei progettisti non sono in contrasto tra loro.
- ⓒ ➤ **Incompatibilità:** R_1 e R_2 sono in conflitto a causa dell'incoerenza nelle specifiche. In altre parole la realtà modellata da R_1 nega la realtà modellata da R_2 .

- A esclusione della situazione di identità, i casi precedenti determinano dei conflitti la cui soluzione rappresenta la componente principale nella fase di integrazione. Le rappresentazioni sono in conflitto diretto e contraddittorio a causa dell'incoerenza nelle specifiche o nei vincoli. La realtà modellata da R_1 nega la realtà modellata da R_2 .

Le rappresentazioni non sono né identiche né equivalenti, ma non sono in contrasto tra loro. Presentano differenze di prospettiva o di copertura (modello), ma le informazioni sono compatibili e possono coesistere.

- **Def.** Si verifica un **conflitto** tra due rappresentazioni R_1 e R_2 di uno stesso concetto ogniquale volta le due rappresentazioni non sono identiche.

A differenza dell'identità, il resto sono conflitti da gestire durante l'integrazione: dobbiamo fare una scelta di modellazione che ci porta in una situazione di identità, così da ottenere lo schema riconciliato

Concetti comuni B



→ Posso fare una query SQL o posso caricare tutti i dati di uno schema nell'altro senza perdere nessuna informazione e viceversa

Def. Due schemi R_1 e R_2 sono **equivalenti** se le loro istanze possono essere messe in corrispondenza uno-a-uno.

□ L'equivalenza tra schemi implica che a livello estensionale esistono sempre due insiemi di dati, diversi ma equivalenti, che memorizzano le stesse informazioni.

Schemi Equi-espressivi

Equivalenti per qualsiasi istanza caricata sul database (equivalenza a livello intensionale)



LIBRO

ISBN	titolo	casa editrice
123445	Il DFM	McGrawHill
4354543	Mi Sembra Logico	LettiTutti
4566454	La Giusta Misura	NonSoloLibri
....		

CASA EDITRICE

nome	indirizzo
McGraw-Hill	via Ripamonti, 89
LettiTutti	Via dei Brutti, 21
NonSoloLibri	Via Tumedei, 57
....	

LIBRO


ISBN	titolo	nome c.e.	indirizzo c.e.
123445	Il DFM	McGraw-Hill	via Ripamonti, 89
4354543	Mi Sembra Logico	LettiTutti	Via Brutti, 21
4566454	La Giusta Misura	NonSoloLibri	via Rossi, 43
....			

Concetti correlati

L'integrazione mette insieme porzioni di realtà che prima erano separate in sistemi distinti. Quando queste porzioni si uniscono nello Schema Riconciliato (globale), le entità prima non collegate si ritrovano vicine, rivelando nuove relazioni semantiche.

- A seguito dell'integrazione, molti concetti diversi ma correlati verranno a trovarsi nello stesso schema dando vita a nuove relazioni che non erano percepibili in precedenza. Tali relazioni sono dette **proprietà inter-schema** e devono essere identificate e rappresentate esplicitamente.

Leggo i due schemi ed ora riesco ad esprimere un nuovo tipo di informazione (Per quali case editrici lavora un Autore)



Quando i due schemi vengono unificati, si trovano per la prima volta nello stesso modello le entità CASA EDITRICE e AUTORE. La realtà aziendale stabilisce un legame logico tra di loro: un AUTORE lavora per una CASA EDITRICE (tramite il LIBRO). Importanza: Questa relazione non era esplicita o percepibile in precedenza perché le due entità erano separate in basi di dati diverse. Una volta integrate, la relazione diventa fondamentale per l'analisi (ad esempio, per un report che analizza quali autori lavorano per una specifica casa editrice). L'identificazione e la modellazione di queste proprietà inter-schema completano lo Schema Riconciliato, trasformandolo da una semplice unione delle parti in una visione aziendale più ricca e significativa.

Le fasi dell'integrazione


(problemi su concetti comuni)

- ^A Risolvere i problemi fin qui elencati ed ^B evidenziare le proprietà che emergono a seguito dell'integrazione degli schemi locali, richiede un complesso insieme di operazioni, per la cui corretta gestione è necessario adottare una metodologia. Le molte metodologie proposte in letteratura concordano sulla sequenza di passi che devono essere svolti e che possono essere così sintetizzati:
 - 1 ➤ **Preintegrazione:** comprende la fase di analisi e di scelta della strategia di integrazione. Consiste nell'analizzare a fondo ogni singolo schema sorgente e normalizzarlo, portandolo a un formato concettuale comune per facilitare il confronto successivo. Inoltre, si decide la strategia di integrazione da adottare.
 - 2 ➤ **Comparazione degli schemi:** durante questa fase gli schemi locali vengono confrontati per evidenziare i conflitti e i concetti correlati.
 - 3 ➤ **Allineamento degli schemi:** durante questa fase il progettista deve risolvere i conflitti precedentemente individuati.
 - 4 ➤ **Fusione e ristrutturazione degli schemi:** gli schemi resi coerenti possono essere fusi a creare un unico schema globale.

Strategie di integrazione

- Indicano l'ordine con cui si procederà all'integrazione degli schemi.
 - **Tecniche ennarie:** processo di integrazione considera più di due schemi contemporaneamente
 - **Tecniche binarie:** il processo di integrazione considera sempre coppie di schemi. Le tecniche binarie sono dette **a scala** quando i nuovi schemi sono integrati allo schema temporaneo **determinato** fino a quel momento.

Il processo di integrazione considera sempre coppie di schemi. Due schemi vengono fusi per crearne uno temporaneo, e poi il risultato viene fuso con il prossimo schema locale, e così via.



Strategie di integrazione

Lavoro sempre con due schemi e quindi è una situazione più semplice (valuto i problemi riguardanti due schemi alla volta), ma ho una visione parziale

poi a seconda della complessità deciderò se ha senso o se riesco a gestirle tutte insieme (A un passo) o se invece conviene gestirle in tempi separati prendendo cluster di schemi che sono simile tra loro e poi faccio un'integrazione a posteriori (iterativo)

- ❑ **L'approccio binario** rende ogni passo di integrazione più semplice grazie al ridotto numero di concetti coinvolti contemporaneamente.
- ❑ Con **l'approccio ennario** ogni concetto viene analizzato avendo a disposizione contemporaneamente tutte le informazioni che lo caratterizzano; inoltre con le tecniche ennarie si diminuisce il numero totale di comparazioni tra concetti poiché ognuno di essi viene analizzato una sola volta.
- ❑ Utilizzando una **tecnica binaria a scala** è possibile definire l'ordine con cui i diversi schemi sorgenti andranno esaminati e aggiunti allo schema riconciliato; normalmente si preferisce iniziare dalle sorgenti che costituiscono il "cuore" del sistema informativo e la cui integrazione definirà lo scheletro dello schema riconciliato.

Accedo a più sorgenti contemporaneamente, quindi l'integrazione sarà più complessa, ma ho una visione completa di tutto

Utilizzato quando ho degli schemi più importanti di altri, su cui baserò il processo di integrazione. I primi schemi verranno utilizzati da riferimento (le scelte vengono fatte per favorire/mantenere i principali).

L'integrazione che ci dà una visione più frastagliata è il processo di integrazione binario bilanciato perché quando faccio le scelte di integrazione per una coppia, non so quali scelte ho fatto per l'altra coppia e quindi posso generare conflitto sulla scelta di integrazione fatta

Binario (semplicità delle scelte vs parzialità delle scelte) ed Ennario (complessità del problema vs visione completa del problema) se la giocano sui rispettivi Trade-Off

2 Comparazione degli schemi

Qualsiasi sia la tecnica che decidiamo di adottare, quello su cui ci dobbiamo concentrare è identificare i concetti comuni ed i conflitti che si possono verificare

- ❑ Questa fase consiste in un'analisi comparativa dei diversi schemi che mira a identificare le correlazioni e conflitti tra i concetti in essi espressi. La sua efficacia dipende dalle conoscenze acquisite dal progettista rispetto al dominio applicativo e alla struttura delle sorgenti informative.

- ❑ I conflitti che possono essere evidenziati appartengono a 4 categorie:

➤ **Conflitti di eterogeneità:** indicano le discrepanze dovute all'utilizzo di formalismi con diverso potere espressivo negli schemi sorgenti (es. E/R e UML). Questo è molto più vero nella necessità di integrare concetti che sono rappresentati in due modelli di dati diversi (esempio: grafo e relazionale, hanno espressività diversa) ➔ scelte di integrazione per ottenere una visione integrata

- **Conflitti sui nomi:** si verificano a causa delle differenze nelle terminologie utilizzate nei diversi schemi sorgenti:


- **Omonimie:** lo stesso termine viene utilizzato per denotare due concetti diversi
- **Sinonimie:** due nomi diversi denotano uno stesso concetto.

- ❑ Mentre le omonimie possono essere individuate da una semplice comparazione dei concetti che presentano gli stessi nomi in schemi diversi, per riconoscere eventuali sinonimi è necessaria una conoscenza approfondita del dominio applicativo. ➤


Riconoscere i sinonimi è molto più difficile e richiede una conoscenza approfondita del dominio applicativo. Il progettista deve affidarsi agli esperti di dominio.

2 Comparazione degli schemi

Sinonimie.... Nomi diversi ma stesso significato



Omonimie.... Nomi uguali ma significato diverso




2 Comparazione degli schemi

Questo caso è un ottimo esempio di come la Diversità di Prospettiva (conflitto semantico) non sia solo un problema di nomi, ma di scelta del modello e del livello di granularità con cui la realtà è stata catturata in ciascun sistema.

Conflitto di tipo Comparabilità: l'informazione portata è diversa, ma non sono incompatibili

I **conflitti semantici** si verificano quando due schemi sorgenti modellano la stessa porzione di mondo reale a un diverso livello di astrazione e dettaglio.



Conflitto Semantico di Prospettiva: Lo schema superiore è sufficiente per il Catasto (codice, indirizzo), mentre lo schema inferiore potrebbe essere necessario per la gestione interna (vendite, manutenzione).

L'integrazione deve risolvere questa differenza di dettaglio:

L'entità **APPARTAMENTO** in entrambi gli schemi è semanticamente la stessa, ma il percorso per raggiungerla dall'**EDIFICIO** è diverso.

Lo Schema Riconciliato dovrà adottare la prospettiva più dettagliata (quella inferiore) e definire un mapping per lo schema superiore che semplicemente "salta" l'entità **PIANO**.

- Il livello di dettaglio adottato negli schemi locali è diverso e di conseguenza anche l'insieme di informazioni rappresentabili cambia.

2 Comparazione degli schemi

I conflitti strutturali si verificano quando la stessa informazione o lo stesso concetto è organizzato e vincolato diversamente negli schemi sorgente, pur riferendosi alla stessa realtà.



I **conflitti strutturali** sono causati da scelte diverse nella modellazione di uno stesso concetto, oppure dall'applicazione di differenti vincoli di integrità. Possono essere classificati in quattro categorie.

- I **conflitti di tipo** si verificano quando uno stesso concetto è modellato utilizzando due costrutti diversi. Riguardano la scelta di come rappresentare un dato concetto (esempio: float da una parte, intero dall'altra).
- I **conflitti di dipendenza** che si verificano quando due o più concetti sono correlati con dipendenze diverse in schemi diversi. Riguardano le regole di connessione tra concetti ed i vincoli di cardinalità (esempio: 1:N da una parte, 1:1 dall'altra) o le dipendenze funzionali tra le entità.
- I **conflitti di chiave** si verificano quando per uno stesso concetto vengono utilizzati identificatori diversi in schemi diversi. Due schemi usano attributi diversi per identificare in modo univoco le istanze della stessa entità.
- I **conflitti di comportamento** si verificano quando diverse politiche di cancellazione/modifica dei dati vengono adottate per uno stesso concetto in schemi diversi. Riguardano i vincoli referenziali e le regole di propagazione delle modifiche definite nello schema (esempio, da una parte se cancello l'edificio cancello gli appartamenti legati, dall'altra parte non accade ciò).

Allineamento e fusione degli schemi

- Con il termine allineamento degli schemi si intende l'eliminazione dei conflitti in essi presenti tramite l'applicazione di trasformazioni agli schemi sorgenti o allo schema riconciliato temporaneamente definito:
 - Cambio dei nomi
 - Cambio dei tipi degli attributi (intero, float, testo).
 - Modifica delle dipendenze funzionali.
 - Modifica dei vincoli esistenti sugli schemi.

Una volta che ho identificato tutte le differenze, devo decidere che scelta fare.

- La soluzione dovrà essere fatta in modo da evitare perdite di informazioni:

intero vs float → float
uno-a-uno vs uno-a-molti → uno-a-molti

però questa cosa non deve portare a rilassare tutti i vincoli dello schema (soprattutto quelli importanti)

cioè non applicare senza avere indagato nel dominio a fondo sempre la regola (esempio: intvsfloat -> float) perché posso andare in contro ad una perdita della correttezza espressiva del nostro schema

Prima di effettuare la conversione, chiedersi come mai funzionava anche se ha un intero/uno-a-uno, nonostante il concetto sia lo stesso?

omonimia, eccessiva cautela (esempio: ho impostato il float per evitare errori spiacevoli in futuro, nonostante lo utilizzi come intero, quindi non avrebbe senso introdurre i decimali)

Controllare la motivazione del conflitto

Allineamento e fusione degli schemi

L'integrazione richiede di scegliere il vincolo meno restrittivo (ad esempio, 1:N anziché 1:1), ma non bisogna esagerare con il rilassamento dei vincoli.

Se si sceglie un vincolo troppo generico per accomodare ogni schema, si potrebbero includere logiche impossibili o contraddittorie per la realtà aziendale.


- ☐ Attenzione però a non eliminare importanti vincoli del sistema per poter includere situazioni impossibili.
- ☐ In caso di incertezza è conveniente preferire le trasformazioni che avvantaggiano gli schemi che si ritengono più centrali nella struttura del futuro schema riconciliato. La strategia migliore è allora quella **binaria a scala**, in cui è possibile iniziare l'integrazione a partire dagli schemi ritenuti più importanti che formeranno il nucleo dello schema riconciliato.
- ☐ La scelta del vincolo (la regola di business) per lo Schema Globale deve essere coerente con la politica aziendale, anche se ciò significa scartare o rifiutare dati provenienti da sorgenti non conformi.
- ☐ Non sempre i conflitti possono essere risolti poiché derivano da inconsistenze di base del sistema informativo; in questo caso la soluzione deve essere discussa con gli utenti che dovranno fornire indicazioni su quale interpretazione del mondo reale basarsi.

4 I principi della fusione

Lo Schema Riconciliato deve contenere tutta la conoscenza (struttura e regole) che era distribuita nei singoli schemi sorgente, più la conoscenza nuova ed emergente che non era percepibile prima dell'unione. Il progettista deve cercare attivamente nuovi legami logici (associazioni, gerarchie) tra entità che ora coesistono nello stesso modello

Completezza: dopo la sovrapposizione degli schemi sorgenti risulteranno evidenti ulteriori proprietà inter-schema che non si erano evidenziate in precedenza. Il progettista deve quindi esaminare lo schema fin qui costruito alla ricerca di nuove proprietà che potranno essere esplicitate inserendo nuove associazioni, gerarchie di generalizzazione.

Minimalità: la sovrapposizione di più schemi può generare una forte ridondanza dei concetti che, sebbene espressi in modo univoco negli schemi sorgenti, risultano duplicati o comunque derivabili l'un l'altro in quello riconciliato. Altre comuni fonti di ridondanza sono le relazioni cicliche tra i concetti e gli attributi derivati



4 I principi della fusione


Il modello finale deve essere facile da comprendere per gli utenti, i progettisti e gli sviluppatori che lo utilizzeranno per costruire report o applicazioni.

Uno schema poco leggibile rallenta e introduce errori nelle fasi successive

→ **Leggibilità:** il miglioramento della leggibilità dello schema facilita e sveltisce le successive fasi di progettazione. Sebbene sia difficile misurare la differenza di leggibilità tra i due schemi, la nozione qualitativa del termine è relativamente semplice.


Integrazione di schemi: un esempio

- “.....I dati riguardano i libri. I libri hanno un titolo. Sono pubblicati da editori che hanno un nome e un indirizzo. I libri sono adottati da Università che hanno un nome e appartengono a uno Stato. Ogni libro è relativo ad alcuni argomenti.....”





Schema 1

- “.....I dati riguardano delle pubblicazioni di diversi tipi. Ogni pubblicazione ha un titolo un editore e una lista di parole chiave. Ogni parola chiave è composta da un nome, un codice e un'area di ricerca.....”



Schema 2

Integrazione di schemi: un esempio




Idea: Identifico i Concetti Comuni e di volta in volta faccio una scelta su qual'è la rappresentazione che mi interessa, fino ad arrivare ad una situazione in cui tutti i concetti comuni individuati (blue con blue e verde con verde) hanno la stessa struttura nei vari schemi e possono essere sovrapposti e quindi fusi


Integrazione di schemi: un esempio

Editore lo rappresento come Entità (viene trasformato nel secondo schema)


①



②




Prima Integrazione dei due schemi (mancano da modificare Libro agganciato ad Università e la non connessione di Libro con Pubblicazione)



Integrazione di schemi: un esempio

Raffinamento dello schema di integrazione di prima (Libro specializzazione di Pubblicazione e solo per i libri ci sono le università)



L'attributo e le due associazioni sono ridondanti

Il mapping è il linguaggio di traduzione che unisce il modello logico (lo schema) ai dati fisici. L'approccio GAV è una tecnica di mapping che definisce il concetto globale in termini dei concetti locali, facilitando l'interrogazione ma rendendo l'architettura meno estensibile.

Il mapping

Il Mapping è l'elemento cruciale che traduce le regole di integrazione (definite a livello di schema) in istruzioni pratiche per il movimento e la manipolazione dei dati.

Adesso ho sorgenti e schema riconciliato, per poter fare il passaggio dei dati dagli schemi sorgenti a riconciliato una tantum (migrazione) o in continuo (Data Warehouse, i DB continuano a convivere ed a parlarsi)

- Il risultato dell'analisi delle sorgenti operazionali finalizzata all'integrazione è composto da due elementi: lo schema riconciliato e il **mapping** ossia **l'insieme di corrispondenze tra gli elementi presenti negli schemi sorgenti e quelli dello schema destinazione.** (legare la struttura delle sorgenti alla struttura dello schema riconciliato/integrato)

- Le funzioni di mapping vengono utilizzate ogniqualevolta si debba eseguire sui database locali una interrogazione espressa sullo schema riconciliato.

L'approccio GAV è una specifica metodologia per definire queste corrispondenze (mapping) ed è centrale nei sistemi di Integrazione Virtuale (Data Federation). Nell'approccio GAV, a ogni concetto dello schema globale deve essere associata una vista. Il significato di questa vista è definito in base ai concetti che risiedono sugli schemi sorgenti (locali).

- GAV (Global-As-View):** a ogni concetto dello schema globale deve essere associata una vista il cui significato è definito in base ai concetti che risiedono sugli schemi sorgenti. (Il GAV è il più usato rispetto al LAV)

Definisco il Global come una vista sui concetti sorgenti

- Riduce l'estensibilità dello schema riconciliato** poiché l'aggiunta di una nuova sorgente richiederà la modifica di tutti i concetti dello schema globale che la utilizzano. la nuova sorgente

(cioè facilita notevolmente il meccanismo di Query Rewriting, che è il cuore dell'integrazione virtuale)

- Facilita la modalità di definizione delle interrogazioni** poiché per capire quali concetti degli schemi sorgenti sono coinvolti sarà sufficiente sostituire a ogni concetto dello schema globale la definizione della vista che lo definisce rispetto ai concetti sugli schemi locali (**unfolding**).

La definizione del mapping è già la traduzione della query SQL

Per capire quali concetti degli schemi sorgenti sono coinvolti in una query globale, è sufficiente sostituire a ogni concetto dello schema globale la definizione della vista che lo definisce rispetto ai concetti sugli schemi locali (processo chiamato Unfolding).

Il mapping

In LAV, lo Schema Globale è definito prima ed in modo autonomo. Successivamente, ogni concetto della sorgente locale è definito come una vista sullo Schema Globale.

Vantaggioso perché se devo attaccare una nuova sorgente non devo modificare/riscrivere lo schema globale, ma semplicemente definisco le viste dal basso (sorgenti) verso l'altro (schema globale)

Lo schema globale è sempre quello ed i concetti sono delle viste sullo schema globale (inverso al GAV)

LAV (Local-As-View): lo schema globale è espresso indipendentemente dalle sorgenti, i cui concetti saranno invece definiti come viste sullo schema globale

Svantaggio

Richiede trasformazioni complesse (*query rewriting*) per capire quali elementi degli schemi sorgenti devono essere presi in considerazione per ricreare il concetto espresso nello schema globale.

Vantaggio

Favorisce l'estensibilità dello schema riconciliato e la sua manutenzione, per esempio l'aggiunta di una nuova sorgente al sistema richiederebbe solo la definizione della vista sullo schema globale che non verrebbe quindi necessariamente modificato

Poiché lo Schema Globale è definito in modo indipendente, l'aggiunta di una nuova Sorgente Z richiede solo la definizione del mapping per la Sorgente Z (come una vista sul Globale), senza dover modificare i mapping o i concetti dello Schema Globale esistente.

Quando un'applicazione interroga lo Schema Globale, il sistema di integrazione (Federation Engine) deve eseguire il processo inverso dell'Unfolding (tipico del GAV). Deve capire quali sorgenti locali (viste sul globale) contengono le informazioni richieste. Il Query Rewriting è computazionalmente molto più complesso in LAV che in GAV, in quanto il sistema deve dedurre la query ottimale da eseguire sulle sorgenti.

GAV: un esempio

// DB1 Magazzino Schema sorgente 1

ORDINI2001(chiaveO, chiaveC, data ordine, impiegato)
CLIENTE(chiaveC, nome, indirizzo, città, regione, stato)
.....

// DB2 Amministrazione Schema sorgente 2

CLIENTE(chiaveC, piva, nome, tel, fatturato)
FATTURE(chiaveF, data, chiaveC, importo, iva)
STORICOORDINI2000(chiaveO, chiaveC, data ordine, impiegato)
.....

```
CREATE VIEW CLIENTE AS
SELECT  CL1.chiaveC, CL1.nome, CL1.indirizzo, CL1.città,
        CL1.regione,          CL1.stato, CL2.tel, CL2.fatturato
FROM    DB1.CLIENTE AS CL1, DB2.CLIENTE AS CL2
WHERE   CL1.chiaveC = CL2.chiaveC;
```

```
CREATE VIEW ORDINI AS
SELECT * FROM DB1.ORDINI2001
UNION
SELECT * FROM DB2.STORICOORDINI2000;
```

Limite della riconciliazione: carico solo i clienti che sono presenti in ENTRAMBI i DB. Servirebbe un Full-Outer JOIN per prendere tutti i clienti di entrambi i DB



Il Cliente in un concetto globale che integri i due schemi non è altro che una vista fatta tramite JOIN su chiave



LAV: un esempio

// DB Riconciliato

ORDINI(chiaveO, chiaveC, data ordine, impiegato)

CLIENTE(chiaveC, piva, nome, indirizzo, città, regione, stato, tel,
fatturato)

.....

// DB1 Magazzino (Definisco il DB del Magazzino come una vista sul DB Riconciliato)

CREATE VIEW CLIENTE AS

SELECT chiaveC, nome, indirizzo, città, regione, stato
FROM DB.CLIENTE;

CREATE VIEW ORDINI2001 AS

SELECT * FROM DB.ORDINI

WHERE data > '31/12/2000' and data > "1/1/2002"



Spiego il Cliente in
termini dello
schema globale

La definizione delle sorgenti locali è semplice ma come faccio a esprimere le interrogazioni dallo schema globale a quello locale ?

Pulizia dei dati

Mentre l'integrazione dello schema (fase intensionale) risolve i conflitti a livello di modello, la pulizia dei dati (fase estensionale) risolve i problemi e gli errori a livello di valore, assicurando che i dati caricati nel sistema integrato (Data Warehouse) siano affidabili.

- ❑ Con il termine **pulizia dei dati** (*Data Cleaning* o *Data Cleansing* o *Data Scrubbing*) si intende l'insieme delle operazioni atte a garantire la consistenza e la correttezza dei dati presenti nel livello riconciliato.
- ❑ Le principali cause di inconsistenza nei dati sono le seguenti:
 - **Errori di battitura.** Sono sempre possibili se al momento dell'inserimento non sono previste procedure di controllo dei valori inseriti (per esempio, il controllo di correttezza del codice fiscale).
 - **Differenza di formato dei dati dello stesso campo.** Si verifica ogniqualvolta l'informazione memorizzata in un campo non sia rigidamente strutturata.

“I”, “IT”, “Italia”

“The Coca-Cola Company”, “Coca Cola”, “Coca-Cola Co.”
 - **Inconsistenza tra valori e descrizione dei campi.** Si verifica a causa dell'evoluzione del modo di operare in azienda o dal variare delle abitudini di vita che rendono indispensabile una informazione di cui non era prevista la memorizzazione.

Esempio: Un campo che registrava "Stato Civile" con valori "Sposato" o "Nubile/Celibe" ora non è più completo per l'evoluzione sociale che include "Unito Civilmente".

Quindi, Pulizia dei dati significa creare delle procedure che vadano o a fare delle verifiche o risolvere i problemi

Pulizia dei dati

Il Singolo campo é corretto, ma se andiamo a vedere il record non sono coerenti

Inconsistenza tra valori di campi correlati. Si verifica quando i valori presenti in due o più campi sono singolarmente corretti ma tra loro inconsistenti.

Possibile da risolvere
tramite formula 'meccanica'

città = 'Bologna', regione = 'Lazio'

➤ **Informazioni mancanti.** Quando le applicazioni del sistema operativo consentono di non riempire alcuni dei campi, la fretta e lo scarso interesse verso un dato spingono spesso l'operatore a tralasciarne l'inserimento.


➤ **Informazioni duplicate.** Si presentano quando due sorgenti forniscono la stessa informazione ma i record utilizzano chiavi diverse. (es. Rossi Mario, via Roma 12 vs. Mario Rossi, via Roma 12A)

Si passa ad un ragionamento per similarità, non più per uguaglianza, per risolvere questo problema

Tecniche basate su dizionari

- Con questo termine si indicano le tecniche di verifica della correttezza dei valori di un campo basate su tabelle di riferimento (*look-up table*) e dizionari per la ricerca di abbreviazioni e sinonimi.
- Sono applicabili solo quando il dominio del campo è conosciuto e limitato.

Le tecniche basate su dizionari sono un metodo per la verifica della correttezza e la standardizzazione dei valori dei campi, applicabili quando il dominio dei valori è conosciuto e limitato.



Se un termine è presente nel dizionario (es. "Coca", "Coca cola", "Coke"), viene sostituito con un termine standard ("Coca cola"). Se non è presente e non è valido, viene scartato.


Il fatto di fare pulizia in un flusso di caricamento comporta che o lo riesco a standardizzare/ripulire o lo scarto

Inconsistenze Correlate

- Le tecniche basate su dizionari possono essere applicate anche a più campi contemporaneamente al fine di verificare eventuali inconsistenze tra due campi correlati. Per esempio, avendo a disposizione una tabella di riferimento che riporta le regioni italiane e, per ognuna di esse, l'elenco delle città che vi appartengono, è possibile verificare se i campi città e regione di un indirizzo sono tra loro consistenti.

Tecniche basate su dizionari

- ❑ Ogniqualvolta si debbano combinare in un'unica destinazione dati provenienti da sorgenti diverse senza una chiave comune, nasce la necessità di identificare i record corrispondenti.




(Eterogeneità di Chiave) Nel caso in cui ho due schemi diversi, so che in entrambi c'è un concetto di cliente, ma da una parte il cliente è identificato da codice fiscale, dall'altra un codice numerico (diverso), ed io devo nello schema riconciliato a livello di integrazione ho definito che esistono i clienti ed gli ordini (effettivamente esistono). Ma come faccio a capire che il cliente che ha un certo CF corrisponde ad un cliente che ha un codice numerico (non ho chiave comune e quindi non posso farlo per uguaglianza il riconoscimento)? Devo farlo tramite tecniche di Join Approssimato

- ❑ È stata scoperta un'associazione implicita tra l'entità DBMARKETING.CLIENTE, DBAMMINISTRAZIONE.ORDINE. Per esplicitare l'associazione è necessario individuare quale cliente ha inoltrato un particolare ordine. Se i due database identificano diversamente i clienti e quindi il join dovrà essere eseguito sulla base dei campi comuni (indirizzo cliente, cognome cliente) che non rappresentano un identificatore per il cliente. In questo caso si parla di **join approssimato** poiché non c'è certezza nella definizione dei record corrispondenti.

Tecniche basate su dizionari

- Quando due istanze diverse di uno stesso schema devono essere fuse assieme si parla di **purge/merge problem**. Le due istanze non sono disgiunte (un cliente può acquistare sia a Roma che a Milano), inoltre anche nei singoli database i clienti potrebbero essere inseriti più volte a causa di errori di battitura che non hanno permesso di verificare un precedente inserimento.



L'unico modo per riconciliare i due schemi in un unico e quindi avere un record per cliente, devo risolvere tramite tecniche di similarità

Funzione di Affinità: La formula mira a calcolare l'affinità tra due stringhe A e B. Questa formula calcola la media della massima affinità tra ogni sottostringa elementare di A e tutte le sottostringhe elementari di B.

Similarità tra record

Stesso metodo che c'è nella slide successiva

Quindi, lavorare per similarità, fondamentalmente, vuol dire andare a cercare se tutti i campi che ritengo essere comuni nella tabella quali sono simili tra loro e quanto simili, e poi costruisco un insieme di regole che mi dicono quando due record sono lo stesso, due record sono simili ma decisione manuale-umana e due record non sono simili

Tecniche basate su funzioni di similarità: comparano le sottostringhe di $A_i \in A$ e $B_j \in B$, calcolando la similarità in base alla formula ricorsiva:

poi ci può essere una parte manuale

Unendo il riconoscimento della stringa estesa da abbreviazioni e media delle massime affinità, si riesce ad identificare l'affinità di moltissime stringhe

$$\text{affinità}(A, B) = \frac{1}{|A|} \sum_{i=1}^{|A|} \max_{j=1}^{|B|} \text{affinità}(A_i, B_j)$$

dopo aver trovato le massime affinità, faccio la media di esse

Questa tecnica riconosce solo similarità sintattica. Con AI, si può riconoscere anche similarità semantica tra record

trovare massima affinità tra le sottostringhe (match migliore)

Pattern di Abbreviazioni: Il confronto tra i sottocampi è basato sulla verifica di abbreviazioni ricercate in base a pattern ben definiti (ci sono software che si occupa solo di questo: comparazione tra sottocampi).

dove la comparazione tra i sottocampi elementari è basata sul confronto tra stringhe e sulla verifica della presenza di abbreviazioni che vengono ricercate in base a pattern ben definiti:

- Un'abbreviazione può essere un prefisso di una sottostringa, per esempio "Univ." è un prefisso per "Università". parte iniziale della parola intera
- Un'abbreviazione può combinare un prefisso e un suffisso di una sottostringa, un esempio è "Dott.ssa" che abbrevia "Dottoressa".
- Un'abbreviazione può essere un acronimo di una stringa, per esempio DEIS è un acronimo per "Dipartimento di Elettronica Informatica e Sistemistica".
- Un'abbreviazione può essere la concatenazione di più prefissi contenuti nella stringa, un esempio "UNIBO" che abbrevia "Università di Bologna".

non applicabile
in tutti i casi



Tecnica di base per trovare similarità di stringhe: distanza di Hamming: numero di caratteri che devo aggiungere/togliere/sostituire da una stringa per ottenere l'altra

Similarità tra record

Principio: Si basa sulla definizione di un set di regole e sul calcolo di una similarità (o "affinità") tra due record P1 e P2.

→ Stesso metodo che c'è nella slide precedente ←

- **Tecniche basate su gruppi di regole:** normalmente vengono valutate caratteristiche quali la edit-distance tra due stringhe o la differenza di valore tra due campi numerici.
- A titolo di esempio si propone, sotto forma di pseudocodice, alcune delle regole, proposte da Hernandez (1998), per la soluzione del purge/merge problem applicato a record contenenti informazioni relative a persone. L'idea di base è di calcolare la similarità tra coppie di record; tutti quelli la cui similarità supera una certa soglia vengono poi fusi in un unico record.

DB Vettoriali (RAG DB): prendo delle porzioni di test o record e ne faccio embedding, cioè li trasformo in un vettore in uno spazio latente, cioè in uno spazio che io non ho definito a priori ma lo ha definito il sistema, e questo meccanismo fa in modo che concetti vicini siano vicini. Ciò mi permette di rappresentare la similarità tra i concetti (esempio, converto due record in questo spazio e verifico se sono simili o no, cioè vicini nello spazio)

Similarità tra record

- ❑ **Tecniche basate su gruppi di regole:** normalmente vengono valutate caratteristiche quali la edit-distance tra due stringhe o la differenza di valore tra due campi numerici.
- ❑ A titolo di esempio si propone, sotto forma di pseudocodice, alcune delle regole, proposte da Hernandez (1998), per la soluzione del purge/merge problem applicato a record contenenti informazioni relative a persone. L'idea di base è di calcolare la similarità tra coppie di record; tutti quelli la cui similarità supera una certa soglia vengono poi fusi in un unico record.

Similarità tra record

□ // Input: due record P1, P2 formati dai campi
(ssns, nome, fname, addr, city, zip)

// Output: VERO = P1 e P2 sono lo stesso record, FALSO = P1 e P2 non
// sono lo stesso record,

```
codiciSimili = comparaCodici(P1,P2);  
nomiSimili = comparaNomi(P1,P2);  
indirizziSimili = comparaIndirizzi(P1,P2);  
cittàSimili = comparaCittà(P1,P2);  
CAPSimili = comparaCAP(P1,P2);  
statiSimili = comparaStati(P1,P2);
```

se (codiciSimili e nomiSimili) allora
restituisce VERO;

indirizziMoltoSimili = indirizziSimili e cittàSimili e (CAPsimili o statiSimili);
se ((codiciSimili o nomiSimili) e indirizziMoltoSimili) allora
restituisce TRUE;

.....

Il pseudocodice mostra un esempio pratico di come le funzioni di similarità vengono combinate in un gruppo di regole per decidere se due record P1 e P2 sono lo stesso record (output VERO o FALSO):

- Confronto per Campo: Vengono calcolate le similarità/affinità per i campi chiave e identificativi (codici, nomi, indirizzi, città, ecc.).

- Regola Rigida (Verità Assoluta):

> se (codiciSimili e nomiSimili) allora restituisci VERO: Se due record hanno sia codici (chiavi) molto simili (o identici) e nomi molto simili, sono considerati lo stesso record (VERO).

- Regola Flessibile (Join Approssimato): se ((codiciSimili o nomiSimili) e indirizziMoltoSimili) allora restituisci TRUE;

> Questa è la regola di join approssimato: se hanno un'alta similarità su un campo identificativo (O), e un'alta similarità anche sui campi secondari (E), vengono considerati probabilmente (TRUE) lo stesso record, superando la soglia di fusione.

Queste tecniche sono essenziali per risolvere il problema dei dati duplicati e per realizzare l'integrazione a livello estensionale (i dati con precisione).

II Master Data Management

- ❑ Con il termine “master data” si indica l'insieme dei dati che identificano e descrivono entità (prodotti, clienti, fornitori, locazioni...) fondamentali per il business di una azienda, che vengono gestiti attualmente da varie applicazioni, sia di tipo operativo che analitico.
- ❑ Definiamo **Master Data Management (MDM)** l'insieme di discipline, tecnologie e soluzioni in grado di creare e mantenere consistenti, aggiornati, accurati e completi i dati di **importanza critica** e di fornire una visione unica ad utenti, applicazioni e processi sia all'interno sia all'esterno dell'azienda.
- ❑ Nell'ambito dell'MDM si distinguono generalmente due aree più specifiche:
 - **PIM** (Product Information Management): incentrata sui Master Data di **Prodotto**
 - **CDI** (Customer Data Integration): incentrata sui Master Data relativi a **clienti/fornitori/utenti**


Integrazione significa aumentare la possibilità di circolarità dell'informazione, quindi sincronizzare i processi e attività sulla base di un dato comune. Se sincronizziamo tra loro le sorgenti dati più importanti/centrali, cioè comuni a più processi, abbiamo già un risultato che ci porta molto avanti nella qualità del dato e nella possibilità di integrazione

Una volta che le entità centrali sono allineate nello Schema Riconciliato, l'integrazione di dati meno importanti (dati transazionali o di supporto) diventa molto più semplice. I nuovi schemi devono semplicemente collegarsi al nucleo coerente già stabilito.

- Problemi di Consistenza: Le diverse copie del dato possono essere aggiornate in momenti diversi o in modi errati in ogni applicazione, portando a visioni contraddittorie (conflitti semantici).
- Inefficienza nei Processi Aziendali: I processi diventano lenti e necessitano di riconciliazione manuale per compensare le incongruenze tra i sistemi, sprecando tempo e risorse.

Il Master Data Management: idea di base

- La dispersione e la ridondanza delle informazioni di importanza cruciale su diverse applicazioni provoca problemi di consistenza e di inefficienza nei processi aziendali



- Per risolvere questi problemi si procede spostando i MD al di fuori delle singole applicazioni. Ciò ha diverse implicazioni

- Viene creata una nuova base dati "master" sincronizzata con quelle esistenti mediante tecniche di data integration in tempo reale
- Si modificano i processi di business che toccano i MD, per alimentare e sfruttare al meglio la nuova base dati "master"
- Va definita la "ownership" dei MD e dei processi di alimentazione e gestione che li riguardano.

Va definita la "ownership" (proprietà e responsabilità) dei MD. Chi è responsabile della qualità e della correttezza del dato "Cliente"? Non può più essere ogni singola applicazione

Scegliere i master data

Per comprendere i Master Data, è utile classificarli rispetto alle altre tipologie di dati presenti in azienda:

Tipologie dei dati

- **Non Strutturati:** E-mail. Documenti pdf, pagine web. Dati che non sono organizzati in un modello fisso
- **Transazionali:** ordini, fatture, trouble ticket. Dati che registrano eventi o attività (fatti) e sono caratterizzati da elevata volatilità e volume.
- **Metadati:** descrizione di attributi, glossario aziendale Dati che forniscono una descrizione su altri dati
- **Gerarchici:** descrivono le relazioni tra i concetti (classificazioni)
- **Master:** persone (clienti, impiegati, fornitori) cose (prodotti, materie prime, negozi, proprietà), luoghi e concetti. I dati anagrafici fondamentali e di riferimento per l'azienda. Sono il contesto con cui si interpretano i dati transazionali.

Caratteristiche dei MD

- **Quantità:** la creazione di un'architettura per la gestione dei MD si giustifica solo per quantità elevate di informazioni (che, senza architettura dedicata, genererebbero altrimenti un'alta ridondanza e inconsistenza)
- **Lifetime:** i MD tendono a essere meno volatili dei dati transazionali. In base a ciò aziende diverse possono fare scelte per la stessa informazione Aziende diverse possono considerare lo stesso tipo di informazione come MD in base alla sua durata.
- ES • I contratti possono essere considerati MD da un'azienda se la loro durata è pluriennale
- **Valore:** maggiore è il valore di una informazione, maggiore la probabilità che sia considerato un MD
- **Complessità:** per dati con limitate problematiche di gestione è poco utile allestire un meccanismo di MDM perché i costi supererebbero i benefici.

Scegliere i master data

□ Caratteristiche dei MD

- **Riusabilità:** un concetto riutilizzato da più sistemi aziendali richiede con elevata probabilità una gestione basata su un sistema di MDM
- **Centralità:** i MD sono centrali a più applicazioni e vengono da essi creati, modificati, letti e cancellati

Tanti soggetti
in azienda che
ci lavorano
con questi dati

	<u>Customer</u>	<u>Product</u>	<u>Asset</u>	<u>Employee</u>
<u>Create</u>	Customer visit, such as to Web site or facility; account created	Product purchased or manufactured; SCM involvement	Unit acquired by opening a PO; approval process necessary	HR hires, numerous forms, orientation, benefits selection, asset allocations, office assignments
<u>Read</u>	Contextualized views based on credentials of viewer	Periodic inventory catalogues	Periodic reporting purposes, figuring depreciation, verification	Office access, reviews, insurance-claims, immigration
<u>Update</u>	Address, discounts, phone number, preferences, credit accounts	Packaging changes, raw materials changes	Transfers, maintenance, accident reports	Immigration status, marriage status, level increase, raises, transfers
<u>Destroy</u>	Death, bankruptcy, liquidation, do-not-call.	Canceled, replaced, no longer available	Obsolete, sold, destroyed, stolen, scrapped	Termination, death
<u>Search</u>	CRM system, call-center system, contact-management system	ERP system, orders-processing system	General Ledger tracking, asset DB management	HR LOB system

La gestione dei Master Data

- ❑ Il MDM non è semplicemente un problema tecnologico, in molti casi impatta pesantemente i processi aziendali e determina problemi di natura politica e organizzativa (complessità tecnologica, ma soprattutto politica e organizzativa)
 - Chi è il proprietario dei dati?
 - Chi è responsabile della loro manutenzione e pulizia?
- ❑ Il MDM include sia la creazione, sia la manutenzione dei MD di conseguenza un progetto di MDM non può essere considerato un'attività una tantum poiché determina una porzione di SI che deve essere mantenuta nel tempo.
- ❑ Le principali fasi di un progetto di MDM sono:
 - Non è mai così semplice identificarli perché si parte sempre da una situazione non completamente strutturata
1. **Identificare le sorgenti dati.** Tipicamente il numero dei DB che memorizzano MD è superiore alle aspettative. (capire quali sono i dati)
 - 2. **Specificare produttori e consumatori di MD.** Il tipo di operazioni e la numerosità degli attori che operano sui MD incidono sulla complessità del processo di gestione (capire chi genera/trasforma/legge quei dati)
 - 3. **Raccogliere meta dati sui MD.** E' fondamentale definire univocamente i MD sia a livello sintattico (formati, tipi di dati), sia a livello semantico.
cioè capire la struttura, formato, valori possibili e definizione semantica dei MD

FASE DI ANALISI

La gestione dei Master Data

□ Le principali fasi di un progetto di MDM sono: (..continua)

- Sono le persone che conoscono come questi dati girano e vengono trasformati
- Fase di Analisi**
4. **Identificare gli esperti dei MD.** Per ogni sorgente si identificano persone in grado di descrivere come i MD debbano essere trasformati per renderli compatibili con la versione condivisa.
- Definisco i flussi di trasformazione (data governance: come voglio gestire i dati)
5. **Definire il processo di data-governance e il relativo gruppo di lavoro.** Il gruppo di lavoro deve avere le competenze e l'autorità per prendere decisioni relativamente a come gestire i MD.
- Fase di Progettazione**
6. **Sviluppare un modello di gestione dei MD.** Dal punto di vista tecnico è la fase più importante del progetto poichè in essa si decide:
- **Quale architettura utilizzare** (come sono organizzate tra di loro Hub centrale e sorgenti)
 - **Quale sarà il formato dei MD** standard (o parti di record)
 - **Quali record saranno inclusi/esclusi** (mi porto dietro solo le informazioni comuni nei vari sotto-sistemi)
- Decidere quale tecnologia utilizzare per realizzare il sistema
7. **Scegliere uno strumento /tool.** Nel caso in cui il sistema di gestione dei MD non sia sviluppato internamente, il tool viene scelto in base al tipo di MD gestiti e alle scelte fatte nella fase precedente.

La gestione dei Master Data

❑ Le principali fasi di un progetto di MDM sono: (..continua)

8. **Progettare e implementare l'infrastruttura di gestione.** L'infrastruttura si occupa di collezionare e rendere disponibili alle applicazioni esistenti i MD.

9. **Generare e testare i master data.** Questo processo iterativo permette di fare evolvere la soluzione grezza al fine di considerare progressivamente tutte le specificità dei dati non catturate durante la prima fase di analisi.

10. **Modificare le applicazioni produttrici e consumatrici di MD.** In base alle interfacce messe a disposizione e in base alle politiche di gestione prescelte le applicazioni che modificano o utilizzano i meta dati dovranno essere modificate. (Dopo di che il sistema va integrato alle varie sorgenti già presenti (continuano a coesistere le sorgenti con Hub integrato)
(Quindi, vanno applicate delle modifiche affinché si possa instaurare la comunicazione con Hub MD)

11. **Definire il processo di manutenzione.** Il processo di manutenzione deve mettere in grado gli esperti dei MD di verificarne la qualità e di correggere gli errori. Il processo deve quindi definire ruoli, modi e tempi per la manutenzione dei MD ma deve anche prevedere gli strumenti di attuazione. Un tool per il controllo dei MD deve per esempio:

garantisce che la qualità e la consistenza dei Master Data (MD) si mantengano nel tempo, impedendo che i dati centrali degenerino nuovamente in stati inconsistenti.


- Mostrare quali inconsistenze si sono verificate sui dati
- Mostrare quale sorgente e quale utente è responsabile dell'incoerenza (data tracing e data auditing)
- Suggerire correzioni

Chi è autorizzato a modificare o approvare un MD

La frequenza con cui i controlli di qualità devono essere eseguiti e le procedure da seguire per la risoluzione dei conflitti.

Complessità di un progetto MDM

Quale fase è risultata più difficile?



Fonte: AMR Research - MDM Strategies for Enterprise Applications (April 2007)

Proprietà Distribuita: La proprietà dei dati rimane delle applicazioni sorgenti che li possono modificare in autonomia. L'Hub MDM non è il sistema che crea o gestisce il dato operativo di primo livello.
Aggiornamento Non Sincrono: L'aggiornamento dei MD nell'Hub non è sincrono con gli eventi che li creano/aggiornano.
Mancanza di Garanzia sull'Aggiornamento: Conseguentemente, l'architettura non garantisce che i MD siano aggiornati in tempo reale. C'è un lag (ritardo) tra l'evento nel sistema sorgente e l'aggiornamento nel Golden Record.

Architetture per MDM: consolidamento

1

L'architettura di Consolidamento è una buona soluzione per migliorare la qualità del dato analitico e per progetti MDM a basso rischio operativo, ma non risolve la necessità di avere un dato centrale aggiornato in tempo reale per le transazioni (a causa della proprietà distribuita e dell'aggiornamento asincrono).

L'architettura viene fisicamente istanziata mediante un hub centrale che contiene i "golden record"

La proprietà dei dati rimane delle applicazioni sorgenti che li possono modificare in autonomia

L'aggiornamento dei MD non è sincrono con gli eventi che li creano/aggiornano conseguentemente l'architettura non garantisce che i MD siano aggiornati


I MD sono utilizzati principalmente per le attività reportistica direzionale (Business Intelligence)

I MD **possono** essere scaricati periodicamente sulle applicazioni che li utilizzano come versione di riferimento (evolvendo in un'architettura di coesistenza)

- Comporta una modifica alle sorgenti che devono prevedere come integrare il dato di ritorno

I MD sono utilizzati per armonizzare il comportamento tra più applicazioni ma non sono utilizzati durante le transazioni dei sistemi sorgente

I MD possono essere scaricati periodicamente sulle applicazioni che li utilizzano come versione di riferimento. Quando avviene questo scaricamento periodico, l'architettura evolve in un'architettura di coesistenza (dove le applicazioni consumatrici sono aggiornate dal Master Hub). Questo comporta una modifica alle sorgenti che devono prevedere come integrare il dato di ritorno.



Reportistica Direzionale: I MD sono utilizzati principalmente per le attività di reportistica direzionale (Business Intelligence). Garantiscono che tutti i report aziendali utilizzino le stesse anagrafiche, risolvendo i conflitti semantici. Armonizzazione, non Transazione: I MD sono utilizzati per armonizzare il comportamento tra più applicazioni ma non sono utilizzati durante le transazioni dei sistemi sorgente.

"Armonizzare" significa far sì che le informazioni e il comportamento di diverse applicazioni siano coerenti, flessibili e allineati tra loro.

Architetture per MDM: a registro ^②


□ Viene costruito un registro centrale che collega le versioni locali dei dati di cui si è verificata la corrispondenza

- Le sorgenti pubblicano i propri dati e l'hub contiene un riferimento ad essi
- La proprietà dei dati rimane delle applicazioni sorgenti che li possono modificare in autonomia
- L'hub esegue gli algoritmi di pulizia e di match tra i record, assegna un identificatore univoco a ogni record distinto e gli associa le versioni corrispondenti nelle diverse applicazioni
- Nessun aggiornamento è inviato alle sorgenti Il Registro è puro consumatore e mappatore di dati.
- Il miglioramento di qualità raggiungibile è limitato Sebbene l'Hub identifichi i duplicati, non li corregge attivamente nelle sorgenti, lasciando il dato "sporco" nel sistema operativo.
- La logica per la ricostruzione del dato è complessa poiché deve agire su più applicazioni : ogni volta che si vuole il dato completo, l'Hub deve interrogare in tempo reale tutti i sistemi sorgente utilizzando le chiavi mappate.
- L'impatto sulle applicazioni e sui processi è limitato poiché i sistemi sorgente non devono essere modificati per ricevere aggiornamenti dal registro.
- I MD sono utilizzati per armonizzare il comportamento tra più applicazioni ma non sono utilizzati durante le transazioni dei sistemi sorgente

- Il cliente 123 del modulo Ordini corrisponde al cliente 257 dell'applicazione Fatturazione

I Master Data sono utilizzati per armonizzare il comportamento tra più applicazioni (come nei report o nei processi di Business Intelligence), ma non sono utilizzati durante le transazioni dei sistemi sorgente. Non garantiscono che il dato transazionale sia corretto al momento dell'inserimento.

- Non Memorizza Dati: L'Hub centrale non contiene i Master Data completi (Golden Record), ma solo un riferimento (link) a essi. Le sorgenti pubblicano i propri dati e l'Hub registra il riferimento.
- Esecuzione degli Algoritmi: L'Hub esegue gli algoritmi di pulizia e di match tra i record.
- Identificatore Univoco (Golden Identifier): Assegna un identificatore univoco a ogni record distinto (il "Golden Identifier") e associa a questo ID le versioni corrispondenti presenti nelle diverse applicazioni.




L'architettura di coesistenza mantiene i vantaggi del consolidamento (un Golden Record centrale) ma introduce la funzionalità di riversamento (distribuzione) dei dati puliti e unificati alle applicazioni sorgenti, creando una vera e propria "coesistenza" tra la sorgente originale e la versione Master.

Architetture per MDM: coesistenza

3

Viene costruito un hub centrale che mantiene una versione aggiornata dei dati che viene in seguito (con modalità non sincrona) riversata sulle sorgenti

- La proprietà dei dati rimane delle applicazioni sorgenti che li possono modificare in autonomia L'Hub MDM non assume il controllo esclusivo sulla creazione o modifica del dato.
- L'aggiornamento dei MD non è sincrono con gli eventi che li creano/aggiornano conseguentemente l'architettura non garantisce che i MD siano aggiornati
 - Normalmente le regole e le tempistiche di aggiornamento sono definite autonomamente dalle singole applicazioni
- Gli MD sono utilizzati per armonizzare il comportamento tra più applicazioni e come punto di riferimento centralizzato Rispetto al Consolidamento, la Coesistenza migliora la qualità del dato anche nei sistemi sorgenti, rendendo i processi operativi più affidabili (sebbene non in tempo reale).



- Hub e Golden Record: Viene costruito un hub centrale che mantiene una versione aggiornata dei dati (il Golden Record), proprio come nell'architettura di Consolidamento.
- Riversamento alle Sorgenti: La differenza chiave è che la versione aggiornata dei dati viene in seguito riversata sulle sorgenti. Questo assicura che anche i sistemi operazionali, che hanno ancora la proprietà dei dati, possano beneficiare della versione pulita e armonizzata del Master Hub.

Questa architettura bilancia il bisogno di un dato centrale autorevole con l'esigenza di non stravolgere i processi operativi che, per ragioni storiche o tecniche, devono mantenere la proprietà del dato.

Architetture per MDM: Transazionale

④

- ❑ Viene costruito un hub centrale che mantiene una versione aggiornata utilizzata in modo sincrono da tutte le applicazioni

Questa è l'unica architettura che garantisce che ogni applicazione stia accedendo alla versione del dato più recente e corretta al momento della transazione.

- La proprietà dei MD è trasferita all'hub che è l'unico soggetto che può modificarli sulla base delle segnalazioni effettuate dalle sorgenti

ma l'Hub MDM deve approvare ed eseguire la modifica.

- Il dato aggiornato deve essere reso disponibile in modo sincrono alle sorgenti

- Si sfrutta principalmente il meccanismo di publish-subscribe dei web service

Quando l'Hub approva una modifica, la "pubblica" e tutti i sistemi "sottoscritti" la ricevono immediatamente.

- Dove possibile è l'hub stesso che aggiorna i db degli applicativi sorgenti in modo da limitare le modifiche alle applicazioni


(tipiche dei database)

- L'hub utilizza politiche transazionali per garantire la consistenza delle informazioni

assicurando che tutti i sistemi ricevano l'aggiornamento o che l'operazione venga annullata (rollback).


- Gli MD sono utilizzati sia nella normale operatività delle applicazioni operazionali sia per armonizzare il comportamento tra più applicazioni

L'architettura Transazionale è l'obiettivo finale per le aziende che necessitano di una visione unica e istantanea per i processi critici



Un esempio concreto: il caso dell'AUSL

- ❑ Un'AUSL vuole valutare possibili soluzioni all'annoso problema dell'anagrafica assistiti
 - I residenti nella provincia di riferimento dell'AUSL
 - I non residenti che per scelta o necessità usufruiscono di prestazioni (es. un ricovero, una visita specialistica) presso gli ospedali, cliniche dell'AUSL
- ❑ Al momento i dati anagrafici degli assistiti sono mantenuti da più applicazioni, tra loro parzialmente incoerenti e ridondanti



AUSL: descrizione della situazione attuale

- ❑ Scelta/Revoca medico di base: è l'ufficio che si occupa, di associare a tutti i residenti un medico di base/pediatra. La scelta/revoca deve essere fatta forzatamente presentandosi all'ufficio
- ❑ CUP - Centro Unico Prenotazioni è l'ufficio che gestisce le prenotazioni per tutte le prestazioni specialistiche. La prenotazione può essere fatta allo sportello oppure telefonicamente utilizzando il codice della ricetta del medico di base
- ❑ Ogni struttura dispone di un ufficio accettazioni che regola ricoveri e dimissioni
- ❑ Il reparto di pronto soccorso ha un proprio sportello di accettazione vista l'urgenza dei ricoveri
 - I pazienti possono giungere al PS in stato confusionale o in stato di incoscienza e devono comunque essere registrati
- ❑ Ogni struttura dispone di più punti di accesso che regolano la fruizione delle prestazioni specialistiche (es. accettazione radiologia, accettazione prelievi del sangue)
- ❑ I flussi regionali permettono di comunicare con le altre AUSL le prestazioni svolte su assistiti non residenti
 - In uscita sono spedite tutte le prestazioni/ricoveri effettuate da NON residenti fatte presso l'AUSL
 - In entrata vengono ricevute tutte le prestazioni/ricoveri effettuate da residenti della provincia (e quindi associati all'AUSL) fatte in altre AUSL

AUSL: descrizione della situazione attuale

- ❑ Come anagrafica principale è stata scelta quella dell'ufficio scelta/revoca del medico di base poichè tale scelta rappresenta una operazione obbligatoria per tutti e soli i residenti e da fare di persona
 - Anche gli assistiti che non fanno prestazioni/ricoveri sono in anagrafica!
- ❑ L'anagrafica principale aggiornata è resa disponibile (in formato .csv) sull'intranet dell'AUSL agli altri uffici con frequenza mensile
 - Non esiste una logica unificata per la fusione degli archivi
 - Gli archivi locali sono spesso più aggiornati visto che è raro recarsi all'ufficio scelta/revoca
- ❑ Ogni applicativo ha una propria struttura relazionale
 - I campi si differenziano nelle diverse applicazioni in base alle funzioni svolte (es. la data dell'ultimo ricovero è presente solo nel db dell'ufficio accettazione ricoveri)
 - I formati non sono standardizzati
- ❑ Per gli assistiti extra-AUSL fanno fede la tessera sanitaria e i dati inseriti al primo contatto (per ogni applicativo)
 - Per gli stranieri senza CF viene inserita una codifica a parte
- ❑ I flussi regionali in entrata sono sempre ritardati di un mese

AUSL: diagnosi della situazione attuale


- ❑ Ogni applicazione può inserire nuovi assistiti. Di conseguenza un errore nell'inserimento del codice sanitario comporta la duplicazione dei dati.
 - Difficile tracciare tutte le prestazioni effettuate da un paziente nelle diverse strutture.
- ❑ L'incoerenza dei dati comporta problemi nelle attività operative
 - Un assistito fa una prenotazione al CUP. La prenotazione e il codice dell'assistito (ma non tutti i suoi dati) sono mandati all'ufficio di accettazione della struttura.
 - Se il codice sanitario è imputato male non risulterà alcuna prenotazione
 - Se l'indirizzo dell'assistito è cambiato i risultati non saranno ricevuti
 - Se il numero di telefono è cambiato non sarà possibile comunicare eventuali variazioni nella prenotazione

AUSL: diagnosi della situazione attuale

- ❑ Solo gli aggiornamenti comunicati direttamente all'ufficio scelta/revoca vengono diffusi a tutte le applicazioni
- ❑ Ogni applicazione deve prevedere un propria procedura di fusione dei dati
- ❑ Il livello di affidabilità delle applicazioni varia fortemente
 - Ufficio scelta/revoca contiene spesso dati obsoleti e parziali (mancanza degli assistiti extra-AUSL)
 - Il Pronto Soccorso è il reparto con dati meno attendibili
 - Il CUP è l'ufficio con i dati più aggiornati perchè è l'ufficio in cui transitano la maggior parte delle prestazioni. I dati sono però meno attendibili se le prenotazioni sono fatte telefonicamente.
- ❑ La frequenza degli aggiornamenti è troppo bassa


AUSL soluzione coesistenza

- Si costruisce un nuovo DB per i master data e si definiscono i flussi di alimentazione da e verso le applicazioni
 - A tutte le applicazioni deve essere aggiunta una procedura per l'integrazione dei dati in ingresso
 - I processi operazionali non sono modificati ma operano semplicemente su dati di qualità migliore (più aggiornati, più completi, più corretti)




- Va definito l'insieme dei dati master/ lasciando sulle applicazioni locali quelli utili solo alla specifica applicazione

AUSL soluzione coesistenza



- ❑ Va definita la struttura standard dei dati e le regole di standardizzazione
 - Il formato deve soddisfare tutte le esigenze informative delle sorgenti ossia deve permettere di alimentarle
- ❑ Vanno definite le politiche di pulizia dei dati
 - Come comportarsi se un indirizzo non esiste?
- ❑ Va definita una politica per il merge dei dati presso l'hub
 - Se la sorgente mantiene la data dell'ultima modifica va considerato il dato più aggiornato
 - Informazioni discordanti vanno valutate in base al livello di affidabilità delle sorgenti
- ❑ Per aumentare la qualità dei dati sarebbe utile concordare la modalità e la tempistica di aggiornamento dei dati presso le sorgenti

AUSL soluzione transazionale



□ Si costruisce un nuovo DB per i master data e si modificano tutte le applicazioni per permettere la gestione transazionale dei dati

1. L'utente del CUP invoca il web service del sistema di MDM richiedendo i dati anagrafici della tessera sanitaria 1344
2. Il web service restituisce l'ultima versione committed dei dati
3. L'utente del cup richiede di modificare l'indirizzo di residenza
4. Se nessuna applicazione sta utilizzando il record e le politiche di qualità sono soddisfatte il record è locked e l'utente cup può apportare le modifiche
 - Solo alcuni uffici possono effettuare le modifiche
5. Il sistema verifica la qualità del dato e accetta/rifiuta l'aggiornamento
6. Il lock viene rilasciato e il dato diventa visibile a tutti

AUSL transazionale vs coesistenza

Questo tipo di strategia è utile quando esistono sia sistemi legacy che devono essere integrati (approccio coesistenza) sia nuove applicazioni da sviluppare con requisiti transazionali moderni.

□ Contro transazionale

- Maggiore impatto sulle applicazioni
- Possibile ~~solo~~ solo se non esistono applicazioni legacy
 - Se ciò non è ^{possibile} ~~verosimile~~ è necessario studiare una strategia mista transazionale-coesistenza
- Assume che tutti i sistemi siano sempre in rete
 - Se temporaneamente un'applicazione non in rete può sfruttare una copia locale dei dati ma non deve permettere l'aggiornamento
- Richiede di definire chi è l'owner del processo di gestione dei MD
 - Non tutti i problemi sono risolvibili da un processo automatico che comunque deve essere supervisionato, fatto evolvere, ecc.

□ Pros transazionale

- Garantisce sempre l'allineamento dei dati tra le applicazioni interne (circolarità dell'informazione)
- Centralizza la gestione dei dati e le politiche di aggiornamento



What's Next: **Integration**, integration integration

- ❑ L'integrazione dei dati è un obiettivo a tendere che i sistemi informativi inseguono dagli anni '70 perché con essa determina:
 - Qualità del dato
 - Ottimizzazione di processo
 - Capacità di analisi
- ❑ Con il procedere della digitalizzazione aumenta il numero di sorgenti dati e diventa sempre più complesso mantenerle integrate e sincronizzate

What's Next: Data Fabric

□ Il **Data fabric** permette un accesso e una condivisione in un ambiente distribuito anche multi-cloud

- Consente un quadro di gestione dei dati unico e coerente, che permette l'accesso ai dati e l'elaborazione senza soluzione di continuità a sorgenti che altrimenti sarebbero ^{isolate} ~~a silo~~
- Sfrutta sia le capacità umane che quelle delle macchine per accedere ai dati sul posto o per supportarne il consolidamento laddove necessario
- Identifica e collega continuamente i dati provenienti da applicazioni diverse scoprendo relazioni rilevanti per il business tra le sorgenti dati disponibili in modo automatico

Il Data fabric

□ ✓ È un'architettura unificata con un insieme integrato di tecnologie e servizi

- Progettata per fornire **dati integrati e arricchiti** - al momento giusto, nel metodo giusto e al giusto consumatore di dati - a supporto dei carichi di lavoro sia operativi che analitici
- Combina le tecnologie chiave di gestione dei dati, ^{in un'unica piattaforma} come il ^{per sapere quali dati esistono e dove sono} catalogo dei dati, la ^{per definire le regole di accesso e qualità} governance dei dati, ^{per il movimento o la virtualizzazione} l'integrazione dei dati, ^{per il flusso dei dati} il pipeline dei dati e ^{per gestire le dipendenze e l'esecuzione dei flussi} l'orchestrazione dei dati

Gartner, 2019 <https://www.gartner.com/en/newsroom/press-releases/2019-02-18-gartner-identifies-top-10-data-and-analytics-technolo>

Gartner, 2021 <https://www.gartner.com/smarterwithgartner/data-fabric-architecture-is-key-to-modernizing-data-management-and-integration>


K2View Whitepaper: What is a Data Fabric? The Complete Guide, 2021

Data Fabric

- Recommendation Engine (4): Un motore di raccomandazione utilizza i metadati attivi per suggerire i flussi di dati, le trasformazioni e le pipeline più appropriate per un dato consumatore. Il sistema sfrutta le capacità delle macchine per accedere ai dati sul posto (virtualizzazione) o supportarne il consolidamento laddove necessario.

- DataOps (6): Il Data Fabric supporta la disciplina DataOps, che integra l'automazione continua, il monitoraggio e il testing per garantire che i dati siano forniti in modo integrato e arricchito - al momento giusto, nel metodo giusto e al giusto consumatore.

Il Data Fabric combina le tecnologie chiave di gestione dei dati (catalogo, governance, integrazione, pipeline e orchestrazione) per superare la necessità di un'unica architettura rigida (come il Transazionale MDM), permettendo all'azienda di accedere ai dati ovunque essi si trovino.



Il Data Fabric inizia con un catalogo dei dati potenziato (Augmented) che non si limita a elencare i dati, ma li arricchisce con metadati.

<https://www.irion-edm.com/data-management-insights/gartner-data-summit-irion-representative-vendor-for-data-fabric-technology/>

What's Next: Data Ops

L'obiettivo di DevOps è accelerare il ciclo di vita del software migliorando la comunicazione, la collaborazione e l'automazione tra gli sviluppatori e gli operatori IT.

❑ **DevOps** deriva dalla contrazione inglese di *development*, "sviluppo", e *operations*, inteso come "messa in produzione" o "deployment"

❑ Dal DevOps al **DataOps** DataOps è l'applicazione di questa mentalità collaborativa e automatizzata di DevOps alla gestione dei dati.

➤ *"A collaborative data management practice focused on improving the communication, integration and automation of data flows between data managers and data consumers across an organization"*

❑ Alcune regole di base

- Stabilire misure di progresso e performance in ogni fase
- Automatizzare il maggior numero possibile di fasi del flusso di dati
- Stabilire una disciplina di governance (governance-as-code)
- Progettare il processo per la crescita e l'estensibilità



Per raggiungere l'efficienza e l'affidabilità, il DataOps si basa su principi fondamentali:

- Misurazione e Performance: Stabilire misure di progresso e performance in ogni fase. Similmente a come si misurano le performance del codice software, si misurano le performance e la qualità dei dati.
- Automazione: Automatizzare il maggior numero possibile di fasi del flusso di dati. Questo include l'automazione del testing della qualità del dato, della preparazione e del deployment delle pipeline dati.
- Governance-as-Code: Stabilire una disciplina di governance formalizzata e automatizzata (definita come governance-as-code). Le regole di governance (come le regole di pulizia del dato o di accesso) sono scritte come codice e applicate automaticamente, garantendo la coerenza in modo continuo.
- Estensibilità: Progettare il processo per la crescita e l'estensibilità. L'architettura deve essere flessibile per accogliere nuove sorgenti dati (scalabilità) e nuovi requisiti analitici.

DataOps è la metodologia che guida l'implementazione pratica di architetture moderne e distribuite come il Data Fabric.

"Una pratica collaborativa di gestione dei dati focalizzata sul miglioramento della comunicazione, integrazione e automazione dei flussi di dati tra i gestori dei dati e i consumatori dei dati all'interno di un'organizzazione"

In sostanza, DataOps mira a rendere il processo di fornitura dei dati (dall'estrazione all'analisi finale) rapido, affidabile e di alta qualità, eliminando i "muri" tra i team IT, i data scientist e gli analisti.



Gartner, 2020 <https://www.gartner.com/smarterwithgartner/how-dataops-amplifies-data-and-analytics-business-value>

Andy Palmer, 2015 <https://www.tamr.com/blog/from-devops-to-dataops-by-andy-palmer/>


William Vorhies, 2017 <https://www.datasciencecentral.com/profiles/blogs/dataops-it-s-a-secret>

What's Next: Data Mesh

In sintesi, il Data Mesh è la risposta organizzativa alla complessità del Data Fabric e mira a decentralizzare la responsabilità dell'integrazione e della qualità dei dati, spingendole verso chi conosce meglio il dato: i team di business.

- *Data mesh is a decentralized sociotechnical approach in managing and accessing analytical data at a scale*

Il Data Mesh è un approccio decentralizzato e sociotecnico per la gestione e l'accesso ai dati analitici su larga scala. A differenza del Data Fabric (che fornisce un livello tecnologico unificato su dati distribuiti), il Data Mesh si concentra sulla proprietà distribuita dei dati all'interno dell'organizzazione.



**Data Mesh:
Delivering
Data-Driven
Value at Scale**


A book by
Zhamak Dehghani

/thoughtworks



- **Obiettivo:** abilitare le organizzazioni a diventare maggiormente Data Driven cambiando il modo in cui queste organizzano i propri team e le proprie architetture dati
- L'approccio data mesh richiede competenze diffuse di Data Architect e Data Science in azienda! Invece di avere pochi esperti centrali che gestiscono tutti i dati, l'expertise deve essere distribuita all'interno di ogni team di dominio.

What's Next: Data Mesh



Limiti delle Data Platform

Sfide Architetture e Tecnologiche

- Col proliferare delle diverse sorgenti informative diventa sempre più complesso **armonizzare i dati all'interno di un modello centralizzato e mantenerlo aggiornato.** Difficoltà di Armonizzazione e Aggiornamento: Col proliferare delle diverse sorgenti informative, diventa sempre più complesso armonizzare i dati all'interno di un modello centralizzato e mantenerlo aggiornato. Questo è un problema diretto della scalabilità dell'MDM Transazionale, per esempio.

Prolifera le Pipeline: Le diverse modalità di fruizione del dato (es. analisi storica vs. machine learning) e la necessità di eseguire sperimentazioni veloci sul dato portano all'esigenza di creare molteplici pipeline di elaborazione.

- Le diverse modalità di fruizione del dato e la necessità di eseguire sperimentazioni veloci sul dato, portano all'esigenza di creare **molteplici pipeline di elaborazione difficili da gestire da un team centralizzato.**

- I continui cambiamenti nelle esigenze di business portano ad elevata complessità nella gestione della **sincronizzazione e prioritizzazione delle pipeline di elaborazione.** Complessità di Gestione delle Pipeline: I continui cambiamenti nelle esigenze di business portano a un'elevata complessità nella gestione della sincronizzazione e prioritizzazione delle pipeline di elaborazione.

Sfide Organizzative e di Governance

Rischio di Distacco dal Business: Questa organizzazione genera la difficoltà nel comprendere a pieno le esigenze del business, creando un divario tra chi gestisce i dati e chi li usa per prendere decisioni.

- I team di lavoro sono organizzati per **competenza tecnologica** (non per competenza di business): **rischio di difficoltà nel comprendere a pieno le esigenze del business e il business ha scarsa fiducia nel dato.**

Scarsa Fiducia nel Dato: Come conseguenza del punto "Rischio di distacco dal business", il business ha scarsa fiducia nel dato fornito dalla piattaforma centrale, a causa di errori, ritardi o dati irrilevanti.

I team di lavoro sono organizzati per competenza tecnologica (non per competenza di business). Ad esempio, esiste un team "ETL/Integrazione" e non un team "Dati sui Clienti".

- Difficoltà nell'individuazione di chi ha **l'ownership sul dato.**

Confusione sulla Proprietà (Ownership): Esiste una difficoltà nell'individuazione di chi ha l'ownership sul dato. Non è chiaro quale team sia responsabile per la qualità e la correttezza di un dato specifico (es. la definizione di "ricavo"), un problema che il Data Mesh risolve assegnando la proprietà ai team di dominio.

I principi del data mesh

1 Domain ownership →

Proprietà Orientata al Dominio

- Concetto: La responsabilità della gestione, della qualità e dell'erogazione dei dati non è più centralizzata in un unico team IT (come avviene nelle piattaforme tradizionali), ma è decentralizzata e assegnata ai team di dominio di business.

- Significato: I dati sono raggruppati logicamente per aree di competenza aziendale (domini), come "Clienti", "Ordini" o "Logistica". Il team responsabile del processo di "Ordine" possiede e gestisce il dato "Ordine". Questo risolve il problema della difficoltà nell'individuazione dell'ownership sul dato.

2 Data as a product

Dati come Prodotto

- Concetto: Ogni team di dominio deve trattare il proprio dato come un prodotto da servire agli altri team interni (i consumatori).

- Implicazione: Per essere considerati prodotti, i dati devono soddisfare determinate caratteristiche di qualità che li rendano utili e affidabili:

> Scopribili (facili da trovare nel catalogo).

> Indirizzabili (facili da connettere).

> Affidabili (alta qualità e tracciabilità).

> Comprensibili (con metadati chiari e leggibili).

> Sicuri (governance applicata).

3 Self-serve data platform

Piattaforma Dati Self-Service

4 Federated computational governance

- Concetto: La governance non può essere centralizzata (altrimenti si ricade nei limiti delle vecchie piattaforme), ma non può nemmeno essere completamente assente. Deve essere federata e computazionale.

Significato:

> Federata: Le decisioni su regole globali (es. privacy, formati standard, qualità minima) sono prese in modo collaborativo da un gruppo inter-dominio (il governance body).

> Computazionale: L'applicazione di queste regole globali (come la sicurezza, l'accesso o la standardizzazione dei metadati) è automatizzata e implementata come Governance-as-Code (un principio ripreso dal DataOps).

- Concetto: Non è realistico chiedere a ogni team di dominio di creare da zero l'infrastruttura per pubblicare i propri prodotti dati. È necessaria una piattaforma centralizzata che fornisca strumenti e servizi self-service.

- Scopo: La piattaforma abilita i team di dominio (che hanno competenza di business) a creare e mantenere i loro prodotti dati senza dover sviluppare autonomamente le competenze di architettura e di integrazione (tipiche dei vecchi team centrali).

1 Domain ownership: domain-oriented decentralization

Nel paradigma Data Mesh, c'è una chiara separazione delle responsabilità:

- Infrastruttura Dati (Centrale): È responsabile unicamente della fornitura delle tecnologie utili alla gestione e al processamento dei dati (la Self-Serve Data Platform).
- Domini (Decentralizzati): Sono responsabili delle pipeline di ingestione, pulizia e aggregazione dei dati al fine di generare gli assets (Data Products) utilizzabili e consumabili da applicazioni e/o altri domini. Questo significa che i team di dominio devono gestire e mantenere le proprie pipeline (ETL) e utilizzare un set di funzionalità della piattaforma per salvare, catalogare e gestire gli accessi ai dati di terzi.

Nel paradigma Data Mesh, l'infrastruttura dati è responsabile della fornitura delle tecnologie utili alla gestione e al processamento dei dati, ma sono i **domini** ad essere responsabili delle pipeline di ingestione, pulizia e aggregazione dei dati al fine di generare assets (Data Products) utilizzabili e consumabili da applicazioni e/o altri domini.

Ogni dominio è responsabile quindi di gestire e mantenere le proprie pipeline (ETL) e un set di funzionalità applicate ad ogni dominio si occupano di salvare, catalogare e gestire gli accessi ai dati di terzi.

- Una volta che i dati sono stati forniti e in seguito trasformati dal rispettivo dominio, gli owners di dominio possono quindi sfruttare i dati per **esigenze analitiche o operazionali**. Questo approccio risolve il problema delle piattaforme tradizionali, dove il team centrale faticava a comprendere a pieno le esigenze operative e analitiche specifiche di ogni dominio.

La decentralizzazione domain-oriented richiede che i team sui domini abbiano competenze pratiche nella gestione e analisi del dato. I **data scientist sono decentralizzati**.

La decentralizzazione basata sul dominio ha un impatto diretto sulla struttura dei team:

- La decentralizzazione domain-oriented richiede che i team sui domini abbiano competenze pratiche nella gestione e analisi del dato.
 - Di conseguenza, figure come i data scientist sono decentralizzati. Essi lavorano direttamente all'interno dei team di business (domini), applicando le loro competenze sui dati che il team stesso produce e mantiene, garantendo una maggiore fiducia e allineamento con gli obiettivi di business.
- Questa transizione è fondamentale perché sposta l'attenzione dalla sola tecnologia alla conoscenza del business come motore per la qualità e il valore del dato.

② Data as a product

Questo principio risolve i problemi storici di data quality e la creazione dei data silo, ovvero l'informazione isolata e inaccessibile, o quello che Gartner chiama dark data (dati raccolti ma mai utilizzati o analizzati).

In sintesi, "Data as a Product" impone che il dato sia trattato con la stessa cura e qualità di un prodotto software o di business, risolvendo alla radice la scarsa fiducia nel dato tipica delle vecchie piattaforme centralizzate.

□ Le caratteristiche più importanti che un Data Product deve mappare sono:

- **Discoverable** e **Addressable**: il Data Product deve fornire intrinsecamente e intenzionalmente tutte le informazioni utili a trovarlo facilmente oltre ad un indirizzo unico di accesso al dato (per fini operazionali e analitici), ad esempio tramite un Data Marketplace.
- **Understandable**, **Trustworthy** e **Accessible**: i Data Products devono esporre informazioni semantiche che permettano la facile comprensione del dato, logiche di quality check, integrity test, lineage e tecniche di accesso native che ne estendano l'usabilità.
- **Interoperable** e **Secure**: perché un data product sia interoperabile occorre utilizzare formati aperti e strutture dati stabili che rispettino le policy definite a livello globale, che prevedono anche aspetti di security e privacy.

affrontare le

□ Il principio del «Data as a product» è pensato per ~~indirizzare~~ problematiche di data quality e dei vecchi data silo, o ancora meglio quello che Gartner chiama dark data.

- Discoverable (Scopribile): Il Data Product deve fornire intrinsecamente e intenzionalmente tutte le informazioni utili a trovarlo facilmente. Ad esempio, deve essere registrato in un Data Marketplace o un Data Catalog.
- Addressable (Indirizzabile): Deve avere un indirizzo unico di accesso al dato (per fini operazionali e analitici). Ciò garantisce che i consumatori sappiano esattamente dove connettersi per accedere alla versione corretta e pulita del dato.
- Understandable (Comprensibile): I Data Products devono esporre informazioni semantiche che permettano la facile comprensione del dato. Questo include la descrizione dei campi e del significato aziendale (metadati).
- Trustworthy (Affidabile) e Accessible (Accessibile): Devono esporre logiche di quality check (controlli sulla qualità), integrity test (test di integrità), lineage (tracciabilità della provenienza) e tecniche di accesso native che ne estendano l'usabilità.
- Interoperable (Interoperabile): Per essere interoperabile, occorre utilizzare formati aperti e strutture dati stabili che rispettino le policy definite a livello globale. L'uso di schemi dati comuni garantisce che i prodotti di domini diversi possano essere combinati senza problemi di coerenza semantica.
- Secure (Sicuro): Le policy globali devono prevedere anche aspetti di security e privacy. Il team di dominio (owner) deve garantire che le regole di accesso definite dalla governance federata siano applicate correttamente.

Data as a product

Le caratteristiche più importanti che un Data Product deve avere sono:

➤ Discoverable e

intenzionalmente
unico di accesso
Data Marketplace

➤ Understandable

informazioni ser
quality check, in
l'usabilità.

➤ Interoperable e Secure.

perché un data product si
formati aperti e strutture dati stabili che rispettino le pol
che prevedono anche aspetti di security e privacy.

Gartner definisce i **dark data** come gli asset informativi che le organizzazioni raccolgono, elaborano e archiviano durante le normali attività aziendali, ma che generalmente non riescono a utilizzare per altri scopi (per esempio, analisi, relazioni commerciali e monetizzazione diretta). Simili alla materia oscura in fisica, i dati oscuri spesso comprendono l'universo delle risorse informative della maggior parte delle organizzazioni. Quindi, le organizzazioni spesso conservano i dati oscuri solo per scopi di conformità. Conservare e mettere in sicurezza i dati comporta tipicamente più spese (e a volte un rischio maggiore) che valore.

Il principio del «Data as a product» è pensato per indirizzare problematiche di data quality e dei vecchi data silo, o ancora meglio quello che Gartner chiama dark data.

Il termine Dark Data definisce gli asset informativi che le organizzazioni raccolgono, elaborano e archiviano durante le normali attività aziendali, ma che generalmente non riescono a utilizzare per altri scopi, come analisi, relazioni commerciali o monetizzazione diretta.

1. Caratteristiche e Conseguenze

- Sebbene comprendano l'universo delle risorse informative della maggior parte delle organizzazioni, rimangono in gran parte inutilizzati.
- Motivazione della Conservazione: Le organizzazioni spesso conservano i dark data solo per scopi di conformità (es. requisiti legali o normativi di archiviazione).
- Bilancio Negativo: Conservare e mettere in sicurezza questi dati comporta tipicamente più spese (ed a volte un rischio maggiore a causa di possibili violazioni) che valore.

2. Il Collegamento con l'Integrazione Dati

- La presenza massiccia di Dark Data è una conseguenza diretta dei limiti delle architetture dati tradizionali:
 - > Silo e Inaccessibilità: Le piattaforme centralizzate, afflitte da data silo e dalla difficoltà di armonizzare e rendere accessibili le molteplici sorgenti, non riescono a trasformare questi dati grezzi in informazioni utili.
 - > Problema della Qualità: Spesso, il dato è "oscuro" perché non è affidabile o comprensibile (mancano i metadati), il che porta gli analisti a ignorarlo.

Il principio del "Data as a Product" nel Data Mesh mira specificamente a contrastare questo problema, trasformando l'informazione dormiente in un asset Discoverable (scopribile), Understandable (comprensibile) e Trustworthy (affidabile), rendendola finalmente utile per analisi e decisioni.

4

Federated Computational Governance

- ❑ Il Data Mesh segue i principi dei sistemi distribuiti, attraverso una collezione di Data Product indipendenti, con una propria gestione del lifecycle messa direttamente in mano ai team di dominio. Al fine di rendere questi Data Product interoperabili tra loro (generando quindi ulteriore valore all'interno dell'organizzazione), un'implementazione di Data Mesh richiede un **modello di governance** che abbracci allo stesso tempo:
 - La decentralizzazione in domini e l'ampia autonomia dei team nella definizione di Data Product. Il modello di governance deve abbracciare la decentralizzazione in domini e l'ampia autonomia dei team nella definizione dei loro Data Product. Ai team è data la libertà di innovare e rispondere rapidamente alle esigenze del loro specifico dominio di business.
 - La definizione di un set di **regole globali** da applicare a tutti i Data Product e alle loro interfacce di comunicazione. Allo stesso tempo, il modello deve definire un set di regole globali da applicare a tutti i Data Product e alle loro interfacce di comunicazione. Queste regole globali riguardano aspetti trasversali come la sicurezza, la privacy, la qualità minima e i formati standard (necessari per l'interoperabilità dei prodotti dati).
- ❑ Un fattore critico di successo per il Data Mesh è quindi riuscire a trovare e mantenere **un giusto equilibrio tra centralizzazione e decentralizzazione**, definendo **quali decisioni debbano essere prese localmente e quali invece vadano definite globalmente**, quali Data Product decentralizzare maggiormente e quali mantenere sotto un'ownership più centrale. Un fattore critico di successo per il Data Mesh è quindi riuscire a trovare e mantenere un giusto equilibrio tra centralizzazione e decentralizzazione. La governance deve definire chiaramente quali decisioni debbano essere prese localmente (dal team di dominio) e quali invece vadano definite globalmente (dall'organo di governance federato). Ciò include anche decidere quali Data Product decentralizzare maggiormente e quali mantenere sotto un'ownership più centrale.

3

Self-Service Platform

Nonostante il Data Mesh sia decentralizzato nella proprietà dei dati, l'infrastruttura di base rimane complessa:

- Competenze Specializzate: Le competenze necessarie per definire e sviluppare un ecosistema infrastrutturale di questa complessità sono altamente specializzate.
- Coordinamento Centralizzato: Per evitare un caos infrastrutturale (dove ogni dominio usa tecnologie diverse), è necessario un coordinamento e una governance architeturale centralizzata.

Per sviluppare, distribuire, eseguire, monitorare e, infine, accedere ai nostri Data Product occorre un'infrastruttura (Data Platform) adeguata. Le competenze necessarie per definire e sviluppare un ecosistema infrastrutturale di questa complessità sono altamente specializzate ed è necessario un coordinamento e una governance architeturale centralizzata.

La Data Platform deve fornire i servizi utili ai team di dominio al fine di poter gestire l'intera filiera dei propri Data Product.

È necessario quindi predisporre una **self-serve data infrastructure**: una Data Platform che espone servizi e funzionalità che abilitano i team di dominio a gestire il ciclo di vita dei Data Product in autonomia.

La funzione principale della Data Platform centrale è quella di supportare i team di dominio in modo che possano concentrarsi sul dato e non sull'infrastruttura:

- Fornire Servizi Utili: La Data Platform deve fornire i servizi utili ai team di dominio al fine di poter gestire l'intera filiera dei propri Data Product.
- Abilitazione Self-Service: È necessario predisporre una self-serve data infrastructure: una Data Platform che espone servizi e funzionalità che abilitano i team di dominio a gestire il ciclo di vita dei Data Product in autonomia.

Questo approccio risolve la tensione tra il bisogno di agilità (data ai domini) e il bisogno di efficienza e standardizzazione (garantita dalla piattaforma centrale). Il team centrale non gestisce più le pipeline ETL (Domain Ownership), ma gestisce e aggiorna gli strumenti che i domini utilizzano per costruire quelle pipeline in autonomia.

Il Data Mesh non fa per voi se....



Il successo dipende dal cambiamento nella proprietà e nei processi, non solo dallo stack tecnologico.

Pensate al Data Mesh come a una tecnologia e non come a un modello operativo

☐ **Pensate al Data Mesh come a una soluzione a scaffale**

Il Data Mesh è un framework architetturale e organizzativo che richiede una progettazione su misura.

☐ **Non è stata definita una Data strategy aziendale**

Senza una chiara strategia che definisca come i dati creano valore, la decentralizzazione risulterà caotica.

☐ **Non emergono business-case (data driven) che portano valore alla business unit (dominio)**

Se i domini non vedono un valore diretto nell'investire nella creazione di un "Data Product", non ci sarà la motivazione per assumersi la Domain Ownership.

☐ **Manca il mindset culturale rispetto a processi di decision-making in modalità bottom-up**

Il Data Mesh richiede che le decisioni sulla gestione dei dati siano spinte dal basso verso l'alto (dai domini) e non imposte centralmente.

☐ **C'è scarsità di risorse *data-addicted* all'interno dell'organizzazione e dei team (data analyst, data scientist, data engineer)**

Poiché il Data Mesh richiede che i data scientist siano decentralizzati e che i domini gestiscano le proprie pipeline (ETL), la mancanza di queste competenze critiche nei team di dominio rende impossibile l'adozione.

Data Mesh vs Data Fabric

- Non Soluzioni Pratiche: Non sono soluzioni pratiche, ma framework architetturali, che devono essere adattati e personalizzati alle vostre esigenze, ai vostri dati, ai vostri processi e alla vostra terminologia.
- Non Si Escludono a Vicenda: Non si escludono a vicenda. In teoria, un'organizzazione potrebbe implementare una strategia di Data Mesh (decentralizzazione organizzativa) sfruttando la tecnologia e gli strumenti di Data Fabric (piattaforma self-service automatizzata).
In sintesi, il Data Fabric è una soluzione tecnologica per la gestione della complessità, mentre il Data Mesh è una soluzione organizzativa per la proprietà della complessità.

□ Data fabric e data mesh definiscono architetture per accedere ai dati attraverso più tecnologie e piattaforme

➤ Data fabric

- Obiettivo Principale • Tenta di centralizzare e coordinare la gestione dei dati
- Affronta la complessità basandosi pesantemente su metadati Gestione del dato

➤ Data mesh

- Obiettivo Principale • Enfasi sulla decentralizzazione e sull'autonomia del dominio dei dati
- Si concentra sul cambiamento organizzativo, sulle persone e sui processi Proprietà del dato

□ Definiscono approcci risolutivi, non soluzioni pratiche

➤ Non si escludono a vicenda

➤ Sono framework architetturali, non architetture

- I framework devono essere adattati e personalizzati alle vostre esigenze, ai vostri dati, ai vostri processi e alla vostra terminologia
- Gartner stima che il 25% dei fornitori di gestione dei dati fornirà una soluzione completa di data fabric entro il 2024, rispetto all'attuale 5%. indicando che il mercato sta rapidamente adottando queste tecnologie basate sui metadati.

Alex Woodie, 2021 <https://www.datanami.com/2021/10/25/data-mesh-vs-data-fabric-understanding-the-differences/>

Dave Wells, 2021 <https://www.eckerson.com/articles/data-architecture-complex-vs-complicated>